

TÜRKİYE CUMHURİYETİ
YILDIZ TEKNİK ÜNİVERSİTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



**DERİN ÖĞRENME İLE MEME ULTRASON TÜMÖRÜ
SINIFLANDIRMASI**

Ç21069012 – CEYDA BABUZ
Ç20069035 – MUHAMMED DİLBER

BİLGİSAYAR PROJESİ

Danışman
Prof. Dr. Gökhan BİLGİN

Ocak, 2026

TEŞEKKÜR

Proje süreci boyunca kıymetli tavsiyeleri, önerileri ve akademik rehberliği ile çalışmamıza yön veren değerli danışman hocamız Prof. Dr. Gökhan BİLGİN'e içtenlikle teşekkür ederiz.

**CEYDA BABUZ
MUHAMMED DİLBER**

İÇİNDEKİLER

KISALTMA LİSTESİ	v
ŞEKİL LİSTESİ	vi
TABLO LİSTESİ	vii
ÖZET	ix
ABSTRACT	xi
1 GİRİŞ	1
1.1 Amaç	1
1.2 Ön İnceleme	1
2 LİTERATÜR ANALİZİ	3
3 SİSTEM ANALİZİ ve FİZİBİLİTE	7
3.1 Sistem Analizi	7
3.2 Fizibilite	8
3.2.1 Teknik Fizibilite	8
3.2.2 Yasal Fizibilite	8
3.2.3 Ekonomik Fizibilite	9
3.2.4 İş Gücü ve Zaman Fizibilitesi	9
4 SİSTEM TASARIMI	11
4.1 Materyal ve Veri Kümesi	11
4.1.1 BUSI (Breast Ultrasound Images) Veri Kümesi	11
4.1.2 Dengesizlik ve Veri Artırma Stratejisi	12
4.1.3 BUS-UCLM Veri Kümesi	13
4.2 Metot	15
4.2.1 Transfer Öğrenme	15
4.2.2 ResNet Mimarisi	16
4.2.3 InceptionV3 Mimarisi	16
4.2.4 DenseNet Mimarisi	17

4.2.5	EfficientNet Mimarisi	17
4.2.6	NASNet Mimarisi	17
4.2.7	Xception Mimarisi	18
4.2.8	Vision Transformer	18
5	DENEYSEL SONUÇLAR	20
5.1	Performans Analizi	20
5.1.1	BUSI Veri Seti Deney Sonuçları	20
5.1.2	BUS-UCLM Veri Seti Deney Sonuçları	27
5.1.3	Alan Uyarlaması Yaklaşımı Deney Sonuçları	30
5.1.4	Vision Transformer (ViT) Tabanlı Mimarilerin Performans Analizi	31
5.2	Karşılaştırmalı Analiz	34
6	SONUÇ VE TARTIŞMA	36
6.1	Kısıtlamalar ve Gelecek Çalışmalar	37
Referanslar		38
Özgeçmiş		40

KISALTMA LİSTESİ

TL	Transfer Learning
CNN	Convolutional Neural Network
MTL	Multitask Learning
ROI	Region of Interest
SVM	Support Vector Machine
HOG	Histogram of Gradients
LBP	Local Binary Patterns
GA	Genetik Algoritma
SOTA	State-Of-The-Art
MLP	Multi-Layer Perceptron

ŞEKİL LİSTESİ

Şekil 3.1 Gantt Diyagramı	10
Şekil 4.1 Proje Blok Diyagramı	11
Şekil 4.2 Veri Setine Ait Örnek Görüşeller	12
Şekil 5.1 EfficientNet 10^{-4} Öğrenme Oranı Karışıklık Matrisi	21
Şekil 5.2 InceptionV3 10^{-3} Öğrenme Oranı Karışıklık Matrisi	22
Şekil 5.3 DenseNet 10^{-3} Öğrenme Oranı Karışıklık Matrisi	24
Şekil 5.4 ResNet-50 10^{-5} Öğrenme Oranı Karışıklık Matrisi	25
Şekil 5.5 NasNetLarge 10^{-3} Öğrenme Oranı Karışıklık Matrisi	26
Şekil 5.6 Xception 10^{-3} Öğrenme Oranı Karışıklık Matrisi	27
Şekil 5.7 Swin Transformer	32
Şekil 5.8 CaiT Transformer	32
Şekil 5.9 DeiT Transformer	32
Şekil 5.10 BEiT Transformer	32
Şekil 5.11 ViT (Standard)	32
Şekil 5.12 Transformer Modellerine Ait Karmaşıklık Matrisleri	32
Şekil 5.13 Swin Transformer	33
Şekil 5.14 CaiT Transformer	33
Şekil 5.15 DeiT Transformer	33
Şekil 5.16 BEiT Transformer	33
Şekil 5.17 ViT (Standard)	33
Şekil 5.18 Transformer Modellerine Ait Karmaşıklık Matrisleri	33

TABLO LİSTESİ

Tablo 1.1 Veri Setlerinin Özelliklerinin Karşılaştırması	2
Tablo 2.1 Literatür Analizi Tablosu	6
Tablo 3.1 Ekonomik Fizibilite	9
Tablo 4.1 Veri Seti Hakkında Bilgi	12
Tablo 4.2 Veri Seti Hakkında Bilgi	13
Tablo 4.3 BUS-UCLM Veri Seti Orijinal Sınıf Dağılımı	13
Tablo 4.4 BUS-UCLM Transfer Öğrenme (TL) Veri Dağılımı	14
Tablo 4.5 Alan Adaptasyonu Senaryoları Veri Dağılımı	14
Tablo 5.1 EfficientNet modelinin öğrenme oranına bağlı performans metrikleri	21
Tablo 5.2 InceptionV3 modelinin öğrenme oranına bağlı performans metrikleri	22
Tablo 5.3 DenseNet modelinin öğrenme oranına bağlı performans metrikleri	23
Tablo 5.4 ResNet-50 modelinin öğrenme oranına bağlı performans metrikleri	24
Tablo 5.5 NasNetLarge modelinin öğrenme oranına bağlı performans metrikleri	25
Tablo 5.6 Xception modelinin öğrenme oranına bağlı performans metrikleri	27
Tablo 5.7 EfficientNet modelinin UCLM veri seti üzerinde öğrenme oranına bağlı performans metrikleri	28
Tablo 5.8 InceptionV3 modelinin UCLM veri seti üzerinde öğrenme oranına bağlı performans metrikleri	28
Tablo 5.9 DenseNet modelinin UCLM veri seti üzerinde öğrenme oranına bağlı performans metrikleri	28
Tablo 5.10 ResNet-50 modelinin UCLM veri seti üzerinde öğrenme oranına bağlı performans metrikleri	28
Tablo 5.11 NasNetLarge modelinin UCLM veri seti üzerinde öğrenme oranına bağlı performans metrikleri	29
Tablo 5.12 Xception modelinin UCLM veri seti üzerinde öğrenme oranına bağlı performans metrikleri	29
Tablo 5.13 %30 eğitim kümesi ile alan uyarlaması sonuçları	30
Tablo 5.14 %50 eğitim kümesi ile alan uyarlaması sonuçları	30

Tablo 5.15 BUSI veri seti üzerinde Transformer tabanlı modellerin sonuçları	31
Tablo 5.16 BUS-UCLM veri seti üzerinde Transformer tabanlı modellerin sonuçları	32

ÖZET

DERİN ÖĞRENME İLE MEME ULTRASON TÜMÖRÜ SINIFLANDIRMASI

CEYDA BABUZ
MUHAMMED DİLBER

Bilgisayar Mühendisliği Bölümü
Bilgisayar Projesi

Danışman: Prof. Dr. Gökhan BİLGİN

Bu çalışma, meme ultrason görüntülerinin normal, iyi huylu (benign) ve kötü huylu (malignant) olarak sınıflandırılmasında derin öğrenme modellerinin başarısını ölçmeyi amaçlamaktadır. Çalışma kapsamında BUSI ve BUS-UCLM veri setleri kullanılarak kapsamlı testler gerçekleştirilmiştir. Yöntem olarak, geleneksel Evrişimli Sinir Ağları (CNN) ile modern Vision Transformer mimarileri karşılaştırılmıştır. CNN mimarileri olarak EfficientNet, InceptionV3, ResNet-50, DenseNet, NasNet ve Xception, modern Vision Transformer varyasyonları olarak ise DeiT, Swin, CaiT ve BEiT karşılaştırmalı olarak analiz edilmiştir. Eğitim sürecinde transfer öğrenme ve alan uyarlaması (domain adaptation) tekniklerinden faydalananlarak farklı veri setleri üzerinde elde edilen sonuçlar karşılaştırılmıştır. Elde edilen bulgular, Vision Transformer modellerinin tıbbi görüntü analizinde CNN modellerine göre daha üstün performans sergilediğini göstermiştir. Özellikle CaiT modeli, %91,30 doğruluk oranı ve %93,10 kesinlik değeri ile en başarılı sonuçları vermiştir. Farklı boyutlarda eğitim kümesi verisi üzerinden yapılan alan uyarlaması senaryolarında ise EfficientNet modelinin kısıtlı veriyle yüksek uyum sağladığı gözlemlenmiştir. Sonuç olarak bu çalışmada elde edilen bulgular, transformer modellerden özellikle CaiT modelinin, farklı veri setlerine uyum sağlama noktasında ise Efficient modelinin, meme kanseri tarama süreçlerinde uzmanlara bir karar destek mekanizması olarak kullanabileceğini göstermektedir.

Anahtar Kelimeler: Meme Kanseri, Ultrason Görüntüleme, Derin Öğrenme, Görüntü

Transformatörü, Alan Uyarlaması, Tıbbi Görüntü Sınıflandırma.

ABSTRACT

BREAST ULTRASOUND TUMOR CLASSIFICATION WITH DEEP LEARNING

CEYDA BABUZ
MUHAMMED DİLBER

Department of Computer Engineering
Computer Project

Advisor: Prof. Dr. Gökhan BİLGİN

This research evaluates the performance of deep learning frameworks in categorizing breast ultrasound images into three distinct classes: normal, benign, and malignant. Utilizing the BUSI and BUS-UCLM datasets, an extensive series of experimental trials are conducted. The methodology depends on a comparative analysis between traditional Convolutional Neural Networks (CNNs)—specifically EfficientNet, InceptionV3, ResNet-50, DenseNet, NasNet, and Xception—and contemporary Vision Transformer architectures, including DeiT, Swin, CaiT, and BEiT. By integrating transfer learning and domain adaptation strategies, the study contrasts performance metrics across varying data environments. The key findings highlight that Vision Transformers generally outperform their CNN counterparts in medical imaging tasks. Especially, the CaiT model emerged as the top performer, yielding an accuracy of 91.30% and a precision of 93.10%. Furthermore, in domain adaptation scenarios involving limited training sets, EfficientNet demonstrated remarkable adaptability. Ultimately, these results suggest that while transformer models like CaiT offer superior diagnostic power, EfficientNet's flexibility makes it a strong candidate for clinical decision-support systems in breast cancer diagnosis.

Keywords: convolutional neural networks, domain adaptation, vision transformer, data augmentation, breast ultrasound images, tumor classification.

1 GİRİŞ

Meme kanseri, kadınlarda en sık görülen kanser türlerinden biridir ve erken teşhis, hastalığın tedavisinde hayatı rol oynamaktadır. Tanı yöntemlerinden biri olan ultrason (US) görüntülemesi; mamografinin aksine radyasyon içermemesi, düşük maliyetli ve özellikle yoğun meme dokusuna sahip hastalarda etkili olması nedeniyle yaygın olarak kullanılmaktadır.

Ancak ultrason görüntülerinin yorumlanması, radyologun tecrübe sine bağlıdır ve bu durum zaman alıcı olabilmektedir. Görüntülerdeki kitlelerin iyi huylu (benign) veya kötü huylu (malignant) olarak ayırt edilmesi, küçük veya belirsiz lezyonlarda zorlayıcı olabilmektedir. Bu noktada motivasyonumuz yapay zeka ve derin öğrenme modellerini kullanarak, ultrason görüntülerine dayalı bir Bilgisayar Destekli Teşhis (CAD) sistemi geliştirmektir. Bu tür bir sistem, hata payını azaltarak teşhis tutarlılığına katkı sağlayabilir.

1.1 Amaç

Bu çalışmanın amacı, meme ultrasonu (BUS) görüntülerindeki kitleleri, derin öğrenme yöntemleri kullanarak sınıflandırmaktır. Temel hedef, geliştirilen modelin bir görüntüyü normal, iyi huylu (benign) veya kötü huylu (malignant) olarak doğru bir şekilde kategorize etmesidir.

Model başarısını değerlendirmek için Performans metrikleri olarak Doğruluk (Accuracy), Duyarlılık (Recall), Kesinlik (Precision) ve F1-Skoru (F1-Score) kullanılacaktır.

1.2 Ön İnceleme

Bu kısmında, projenin daha önceden yapılmış olan çalışmalarda kullanılan halka açık ultrason veri setleri incelenmiştir. Projemizde ana eğitim veri seti olarak BUSI

(Breast Ultrasound Images), modellerin farklı klinik ortamlardaki dayanıklılığını test etmek ve Alan Uyarlaması (Domain Adaptation) çalışmalarını yürütmek amacıyla ise BUS-UCLM veri seti seçilmiştir.

BUSI'nın seçilmesinin temel nedeni, yaygın kullanım avantajıyla literatürde bir kıyaslama (benchmark) noktası olması ve projemizin amacına uygun olarak 3 sınıfı (normal, iyi huylu, kötü huylu) bir etiketlemeye sahip olmasıdır. BUS-UCLM veri seti ise, yine 3 sınıfı yapısıyla BUSI üzerinde eğitilen modellerin farklı cihaz ve hasta popülasyonlarından gelen veriler üzerindeki genelleme yeteneğini ölçmek (Domain Adaptation) için projeye dahil edilmiştir.

İncelediğimiz diğer alternatifler olan Dataset B, BrEaST ve UDIAT-BUS, hem yetersiz data düşük görüntü sayısı hem de sadece 2 sınıf (normal doku olmadan) içermeleri nedeniyle elenmiştir.

Tüm bu veri setlerinin ortak dezavantajları, derin öğrenme modelleri için görüntü sayısının yetersiz olması ve ultrason görüntülerine özgü 'Speckle Gürültüsü' nedeniyle işlenmesi zor olmalarıdır. Aşağıdaki Tablo 1.1'de veri setlerinin özelliklerinin karşılaştırılması verilmiştir.

Tablo 1.1 Veri Setlerinin Özelliklerinin Karşılaştırması

Özellikler	BUSI	Dataset B	BUS-UCLM	BrEaST	UDIAT-BUS
Görüntü Tipi	Ultrason	Ultrason	Ultrason	Ultrason	Ultrason
Görüntü Sayısı	780	163	683	256	163
Sınıflar	3	2	3	2	2
Avantajlar	Yaygın kullanım	Temel 2-sınıflı	Alan uyarlamasına uygun	Temel 2-sınıflı	Temel 2-sınıflı
Dezavantajlar	Sınıf Dengesizliği	Yetersiz data ve 2 sınıf	Sınıf Dengesizliği	Yetersiz data ve 2 sınıf	Yetersiz data ve 2 sınıf

2 LİTERATÜR ANALİZİ

Çalışmanın bu aşamasında, literatürdeki makaleler taranarak ilgili çalışmalar incelenmiş ve analiz edilmiştir. Makalelerde lezyon sınıflandırması çoğunlukla kötü huylu(malignant) ve iyi huylu(benign) tümör olmak üzere iki kategoriye ayrılarak gerçekleştirılmıştır. Veri setleri incelendiğinde çok sayıda görüntü verisi içeren veri setlerinin yanında sınırlı sayıda görüntü içeren veri setleri de bulunmaktadır. İncelenen çalışmaların çoğunda bu veri setleri data augmentation yapılarak görüntüler farklı rotasyonlarda ve boyutlarda yapay olarak çoğaltılmış ve modelin genellemeye yeteneğinin artırılması hedeflenmiştir. Kullanılan mimariler, yaklaşımlar ve yöntemler bazında özellikle son 5 yıldaki makaleler ele alındığında derin öğrenme modellerinin öne çıktığı görülmektedir. Bu modeller yaygın olarak kullanılan AlexNet, VGG, ResNet gibi geleneksel evrişimli sinir ağı mimarilerinden başlayarak çeşitli transformer modellere kadar birçok yaklaşımından faydalananmıştır.

Baz modellerde doğrudan sınıflandırma modelleri kullanılırken, bazı çalışmalarda önce segmentasyon yapılarak ROI yaklaşımıyla tümörün ilgili kısmı kırılmış, ancak güncel literatürde bu temel yaklaşımların ötesine geçildiği görülmektedir. Özellikle MobilNet gibi hafif mimarilerin kullanıldığı yöntemlerde bile, genetik Algoritma ile öznitelikler optimize edilerek sınıflandırma başarısı artırılmıştır. Daha ileri düzeyde yaklaşımlarda ultrason ve mamografi gibi çoklu modalite kullanımı veya VGG, ResNet ve Inception gibi farklı Transfer Öğrenimi modellerinden çıkarılan öznitelikleri birleştirilerek ve sonrasında olasılıksal optimizasyon uygulanarak sınıflandırma başarısı arttırmıştır. Hatta bazı çalışmalar, CNN'in iç mimarisine dikkat mekanizmaları ekleyerek modelin kritik morfolojik detaylara odaklanmasını sağlamıştır.

Cruz-Ramos vd. (2023) [1] tarafından yapılan çalışmada literatürde yaygın olarak kullanılan ultrason görüntülerinden oluşan BUSI veri setiyle beraber mamografi görüntüleri içeren mini- DDSM adlı veri seti kullanılmıştır. Bu sayede iki farklı görüntüleme yöntemlerinden elde edilen görüntüler sağlanarak farklı veri türleri birleştirilmiştir. Metodoloji kısmına bakıldığından ise DenseNet CNN mimarisi

ile beraber geleneksel el yapımı öznitelikleri birleştiren hibrit bir yaklaşım benimsenmiştir. Lezyonun şekli, dokusu ve çevresel alan bilgisi gibi önemli özelliklerini yönelik gradyanlar histogramı ve yerel ikili örüntüler yöntemleriyle öznitelik çıkarma aşamasında kullanılmıştır. Segmentasyon işleminde ultrason görüntüleri için manuel olarak radyolog tarafından sağlanan segmentasyon maskeleri kullanılmıştır. Mamografi için ise bounding box yani nesneyi çevreleyen sınırlayıcı kutu kullanılmıştır. Füzyon aşamasında ise genetik algoritma ve mutual information teknikleri kullanılmıştır. Final sınıflandırma olan kötü huylu ve iyi huylu doku ayrımında ise XGBoost AdaBoost ve MLP gibi çeşitli sınıflandırıcılar kullanılmış ve bu iki görüntüleme yöntemini de içeren hibrit sistem ile %97,6 doğruluk oranı elde edilmiştir. Bu çalışma özellikle farklı görüntü türlerini birleştiren bir çalışma olmakla öne çıkmaktadır.

Alrubaie vd. (2023) [2] tarafından yapılan derin öğrenme tabanlı çalışmada öncellikle veri seti iki kategoriye ayrılarak birinde 3 sınıfı (kötü huylu, iyi huylu, ve normal) diğerinde ise 2 sınıfı (kötü huylu ve iyi huylu) olarak kullanılmıştır. Çalışmada 4 katmanlı sade bir CNN mimarisi kullanılarak bu iki veri seti üzerinde değerlendirme yapılmıştır. Augmente edilmemiş üç sınıfı sınıflandırmada %96, augmente edilmiş dengeli bir veri seti ile iki sınıfı sınıflandırmada %100 doğruluk elde edilmiştir. Model, transfer learning kullanmadan sadece 10 epoch ile eğitilmiş ve ReLU aktivasyon fonksiyonu ile SoftMax çıkış katmanı tercih edilmiştir. Bu çalışmanın ikinci veri setinde %100 doğruluk oranına ulaşması overfitting probleminin göstergesi olabilmekle beraber çapraz doğrulama işleminin yapılmaması da çalışmadaki metodolojik kısıtlamalardan biridir.

Hossain vd.[3] tarafından 2023 yılında yapılan çalışma, meme tümörü tanısında önemli bir problem olan segmentasyon ve sınıflandırma görevlerini art arda (kaskat/sequential) kullanan hibrit bir sistem sunmaktadır. Önerilen yöntem, öncelikle tümör bölgesini doğru bir şekilde belirlemek için hibrit UNet tabanlı bir model ile segmentasyon işlemini gerçekleştirir. Ardından, bu ilk aşamada elde edilen hassas kırılmış tümör görüntülerini, nihai Benign/Malignant ayrimını yapmak üzere fine-tuned edilmiş bir CNN sınıflandırma modeline girdi olarak verilir. Bu kaskat yaklaşım, geleneksel tek aşamalı sınıflandırmaların aksine, modelin dikkatini arka plan gürültüsünden arındırılmış, sadece tümörün kritik şekil ve sınır özelliklerine odaklamasını sağlayarak tanısal doğruluğu artırmayı amaçlamıştır.

Yukarıda bahsedilen çalışmalarдан farklı olarak He vd.[4] tarafından 2024 yılında yapılan çalışma çoklu görev öğrenimi(Multitask learning- MTL) yaklaşımını uygulamaktadır. ACSNet (Attention-based Contextual Segmentation Network) kullanarak ultrason görüntülerinde segmentasyon ve sınıflandırma işlemlerini eş

zamanlı olarak optimize etmeyi amaçlar. Önceki MTL yöntemlerinin yaşadığı gereksiz bilgi aktarımı sorununu çözmek için, segmentasyon ağında bağlamsal bilgi transferini kontrol eden yeni bir "Gate Unit" ve tümörün şeiksel varyasyonlarıyla başa çıkan Deforme Edilebilir Uzamsal Dikkat Modülü (DSAModule) gibi yenilikler sunulmuştur. Sınıflandırma kısmında benign ve malignant tümörleri daha iyi ayırt etmek için çok ölçekli öznitelik çıkarımı ve kanal dikkat mekanizmaları entegre edilmiştir. Oluşturulan model, iki adet halka açık BUS veri kümesi üzerinde test edilmiştir ve SOTA sonuçları elde etmiştir. Atrey vd. (2024) tarafından yapılan çalışma yine Cruz-Ramos vd. (2023) [1] tarafından yapılan çalışma gibi hem ultrason hem de mamografi görüntülerini birleştirerek çoklu modalite füzyonu yaklaşımından yararlanmaktadır. Kullanılan yöntemlere bakıldığından derin öznitelik çıkarmak için ResNet-18 Transfer Öğrenimi mimarisi kullanılmış ve elde edilen ultrason ve mamaogram öznitelik vektörleri birleştirilerek hibrit öznitelik vektörü oluşturulmuştur. Sınıflandırma aşamasında derin öğrenme yerine makine öğrenimi yaklaşımlarından Support Vector Machine (SVM) faydalانılmıştır ve %99,2 doğruluk oranı elde edilmiştir. Bu makalede kullanılan veri kümesi ise 31 hastadan toplanan ultrason ve mamografi görüntülerini içeren özel bir veri kümesidir.

Çalışkan vd. (2022) [5] tarafından yapılan çalışmada tek bir model yine önceden eğitilmiş çoklu evrişimsel sinir ağlarından oluşan bir yaklaşım sunulmaktadır. Üç sınıfı bir veri kümesiyle yapılan bu çalışmada VGG, ResNet ve Inception gibi farklı mimarilerden elde edilen derin öznitelikleri yakalamak için Transfer Öğrenimi stratejisi kullanılmıştır. Her modelin son katmanlarından çıkan öznitelikler, sınıflandırma yapılmadan önce birleştirilerek tek bir vektor oluşturulur. Bu strateji, her modelin farklı öznitelik türlerini (yerel doku, yapısal derinlik, çok ölçekli bağlam) yakalamasından kaynaklanan tamamlayıcı bilgiyi kullanarak, tekil modellere kıyasla üstün performans sağlamıştır. Deneysel analizler sonucunda %99,57 oranında bir doğruluk başarısı elde edilmiştir.

BUSI veri kümesi kullanılarak yapılan çalışmalardan bir diğeri de Kormpos vd.(2025) [6] tarafından yapılan çalışmадır. Bu çalışmada amaç diğer çalışmalarдан biraz daha farklı olarak yaygın kullanılan mimariler kapsamlı şekilde değerlendirilerek modellerin başarıları karşılaştırılmıştır. Karşılaştırılan mimariler, VGG, ResNet, Inception ve DenseNet gibi çeşitli Transfer Öğrenimi mimarileridir. Karşılaştırma sonucu derin öğrenme mimarilerinin doğruluk, hız ve parametre kullanımı açısından farklılık gösterdiğini ortaya koymuştur. Elde edilen sonuçlar, MobileNetV2 gibi hafif mimarilerin verimlilik hedefleri için, DenseNet ve ResNet gibi mimarilerin ise yüksek sınıflandırma doğruluğu hedefleri için en uygun seçenekler olduğunu göstermiştir.

Optimize edilmiş bir derin öğrenme mimarisi sunan Liu vd. (2025)[7] tarafından

yapılan çalışmada önerilen model incelemesinde temel olarak bir CNN mimarisi görülmektedir. Fakat bu modelde öznitelik çıkarım sürecini iyileştirmek adına dikkat mekanizmaları ve gelişmiş bloklar entegre edilerek daha gelişmiş bir sunulmuştur. Model, bu iyileştirmeler sayesinde tümör sınırları gibi kritik morfolojik bilgilere daha iyi odaklanabilmekte ve temel CNN mimarilerine kıyasla daha yüksek sınıflandırma doğruluğu sergilemiştir.

Jabeen vd. (2022) [8] tarafından yapılan çalışmada ise diğer çalışmalara benzer olarak VGG19, ResNet50 ve InceptionV3 transfer öğrenimi mimarileri kullanılmıştır. Ön işleme, derin öznitelik çıkarımı, öznitelik füzyonu, olasılıksal seçim ve sınıflandırma aşamalarından oluşan 4 aşamalı çalışmanın ayırt edici noktası ise füzyon sonucu elde edilen büyük öznitelik vektöründen, en ayırt edici öznitelikleri seçmek için olasılıksal yöntemler kullanılmasıdır. İkinci aşamada, bu farklı modellerden gelen öznitelikler seri birleştirme ile tek bir büyük füzyon vektöründe toplanmıştır. Son olarak, optimize edilmiş öznitelik vektörü Destek Vektör Makinesi gibi geleneksel bir sınıflandırıcıya veya basit bir tam sağlıaklı katmana beslenmiştir. Öznitelik füzyonu aşaması ardından yapılan optimizasyon sayesinde sınıflandırma sonucunda %99'un üzerinde doğruluk başarısı elde edilmiştir.

Tablo 2.1 Literatür Analizi Tablosu

Yazarlar ve Yıl	Veri Kümesi	Temel mimariler	Yaklaşım
Cruz-Ramos vd. 2023	BUSI ve mini-DDSM	DenseNet 201 + XGBoost/MLP	HOG/LBP +CNN
AL-rubaie vd. 2023	BUSI	4 katmanlı CNN mimarisi	CNN
Hossain vd. 2023	BUSI	Hibrit UNet ve fine-tuned CNN	Sequential/Cascade System
He vd. 2024	BUSI ve BUS	ACSNet	Multitask Learning
Atrey vd. 2024	Private dataset	ResNet-18	Transfer Learning
Çalışkan vd. 2022	BUSI	VGG, ResNet, Inception	Transfer Learning
Kormpos vd. 2025	BUSI	VGG, ResNet, Inception ve DenseNet	Transfer Learning
Liu vd. 2025	BUSI	RcdNet ve Deep Network	CNN+Attention mekanizmaları
Jabeen vd. 2022	BUSI	DarkNet, VGG19, ResNet50 ve InceptionV3	Öznitelik füzyonu ve olasılıksal seçim

3

SİSTEM ANALİZİ ve FİZİBİLİTE

Sistem analizi başlığı altında, projenin başarılı bir şekilde tamamlanması için zorunlu olan teknik ve işlevsel gereksinimler tanımlanacaktır.

3.1 Sistem Analizi

Projemizin hedefi, meme ultrasonu (BUS) görüntülerinin derin öğrenme yaklaşımları kullanılarak doğru bir şekilde sınıflandırılmasıdır. Temel amaç, ultrason görüntülerindeki potansiyel kitleleri normal, iyi huylu veya kötü huylu olarak üç sınıfa ayırabilen bir sistemi geliştirmektir.

Bu hedefe ulaşmak için öncelikle doğru ve güvenilir bir veri seti bulunması kritik bir gereksinimdir. Yapılan literatür taraması ve veri seti araştırması sonucunda, projede ana bilgi kaynağı olarak BUSI (Breast Ultrasound Images) veri setinin kullanılmasına karar verilmiştir. Bu veri seti, 780 adet etiketlenmiş görüntü içermesi ve incelen bir çok akademik çalışmada temel bir kıyaslama veri seti olarak kullanılması nedeniyle en uygun çözüm olarak belirlenmiştir. Bunun yanısıra Alan uyarlaması içinse BUS-UCLM dataseti kullanılmıştır. Özellikle bu versetinin BUSI gibi üç sınıflı olması bu alanda kullanılmasında etkili olmuştur.

Sistemin başarısını ölçmek için, incelenen makalelerde de yaygın olarak kullanılan performans metrikleri belirlenmiştir. Bu metrikler; Doğruluk (Accuracy), Duyarlılık (Sensitivity/Recall), Kesinlik (Precision) ve F1-Skoru (F1 Score)'dur. Ayrıca, modelin verimliliğini değerlendirmek için hesaplama süresi de dikkate alınacaktır.

Proje sürecinde, BUSI ve BUS-UCLM veri setlerindeki görüntü sayıları derin öğrenme modellerinin eğitimi için sınırlı olduğundan, modelin ezberlemesini önlemek amacıyla veri artırma teknikleri zorunlu bir gereksinim olarak belirlenmiştir. Görüntüler, modellere girdi olarak verilmeden önce yeniden boyutlandırma gibi önişleme adımlarından geçirilecektir.

3.2 Fizibilite

Bu bölümde, "Derin Öğrenme ile Meme Ultrason Tümörü Sınıflandırması" projesinin fizibilite etüdü sunulmaktadır. Çalışmanın uygulanabilirliğini değerlendirmek amacıyla; yazılım, donanım, yasal, ekonomik ve zaman planlaması gibi temel kısıtlar bakımından analiz edilecek ve projenin genel bir değerlendirmesi yapılacaktır.

3.2.1 Teknik Fizibilite

3.2.1.1 Donanım Fizibilitesi

Proje geliştirme, kodlama ve önişleme süreçleri için proje ekibinin mevcut Monster dizüstü bilgisayarı (Intel i5-10300H, 16GB RAM, NVIDIA GTX 1650) kullanılacaktır. Bu donanım, temel sistem gereksinimlerini karşılamak için yeterlidir.

Derin öğrenme modellerinin eğitim) için kullanılacak orijinal BUSI veri seti (780 görüntü) yetersizdir; bu nedenle modelin ezberlemesini önlemek amacıyla veri artırma teknikleri uygulanacaktır. Bu işlem, eğitim veri setini büyütceği için yüksek hesaplama gücü gerektiren bir eğitim yükü oluşturacaktır.

Bu eğitim yükünün yerel donanımdaki yavaş eğitim sürelerinin önüne geçmek için Google Colab platformunun sunduğu ücretsiz GPU hizmetinden faydalanaacaktır. Hem orijinal veri setinin hem de eğitim sırasında oluşturulacak artırılmış görüntülerin depolanması için mevcut SSD ve bulut depolama alanı yeterlidir.

3.2.1.2 Yazılım Fizibilitesi

Projenin Yazılım Fizibilitesi için, derin öğrenme alanında sunduğu zengin geniş kütüphane desteği ve esnekliği nedeniyle Python programlama dili tercih edilecektir. Veri setinin (BUSI) yüklenmesi, işlenmesi ve veri artırma işlemleri için OpenCV, Numpy ve Pandas kütüphanelerinden; modellerin oluşturulması ve eğitimi ise TensorFlow ve Keras kütüphanelerinden faydalanaacaktır. Sonuçların görselleştirilmesi için Matplotlib kullanılaraktır. Bahsi geçen tüm bu Yazılım Araçları açık kaynak kodlu ve ücretsiz olup, Ekonomik Fizibilite)bölümünde belirtildiği gibi ek bir maliyet oluşturmamaktadır.

3.2.2 Yasal Fizibilite

Projenin yasal fizibilitesi, öncelikli olarak medikal veri kullanımıyla ilgili kanunlara ve yönetmeliklere odaklanmaktadır. Projede, "BUSI (Breast Ultrasound Images)" adlı, akademik araştırmalar için yayınlanmış, halka açık bir veri seti kullanılacaktır.

Bu veri seti, hasta mahremiyetini korumak amacıyla tamamen anonim hale getirilmiştir; görüntüler herhangi bir kişisel bilgi yoktur. Bu durum, projenin Kişisel Verilerin Korunması Kanunu ve benzeri uluslararası veri koruma yönetmeliklerine uygun olmasını sağlamaktadır.

Projede kullanılacak olan derin öğrenme mimarileri ve yazılım kütüphaneleri açık kaynak kodlu lisanslara sahip olup, akademik araştırma amaçlı kullanıcıları serbesttir. Bu nedenle, geliştirilecek yazılımın bilinen bir patenti veya korunmuş bir hakkı ihlal etmesi söz konusu değildir.

Sonuç olarak, proje anonimleştirilmiş ve halka açık bir veri seti ile açık kaynaklı teknolojiler kullanacağı için yasal açıdan herhangi bir sorun teşkil etmemektedir.

3.2.3 Ekonomik Fizibilite

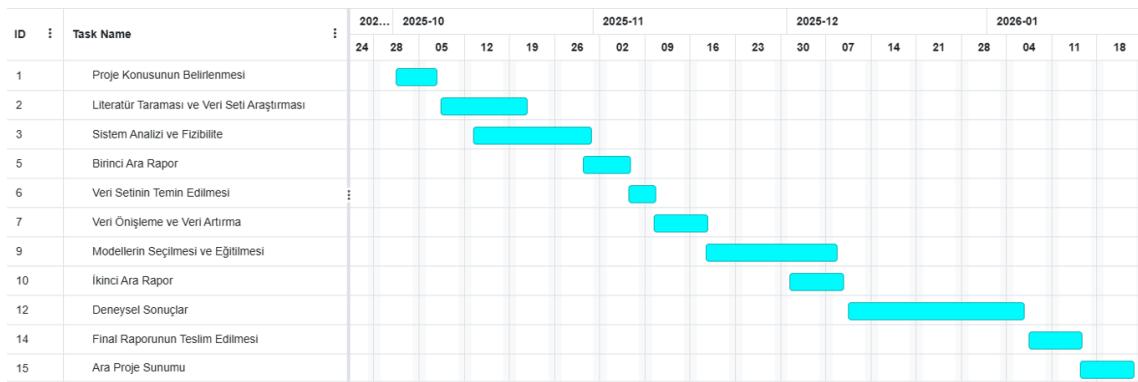
Model eğitimi için ihtiyaç GPU (donanım) gücü, Google Colab platformunun ücretsiz sürümü kullanılarak karşılanmış ve bu gider kalemi için ek bir maliyet oluşmamıştır. Bu kapsamında kullanılan sistemler Tablo 3.1'de detaylandırılmıştır.

Tablo 3.1 Ekonomik Fizibilite

Kalem	Açıklama	Maliyet(TL)
Bilgisayar	Intel i5-10300H, 16GB RAM, NVIDIA GTX 1650	30000
İşletim Sistemi	Windows 11	6600
Kütüphaneler	Python; TensorFlow, Keras kullanılacaktır.	0
GPU (İşlem Gücü)	Eğitimi için Google Colab kullanılacaktır.	0
Proje Ekibi	Dışarıdan bir iş gücü alımı olmayacağı.	0
Veri Seti ve Lisanslar	Halka açık BUSI veri seti kullanılacaktır.	0

3.2.4 İş Gücü ve Zaman Fizibilitesi

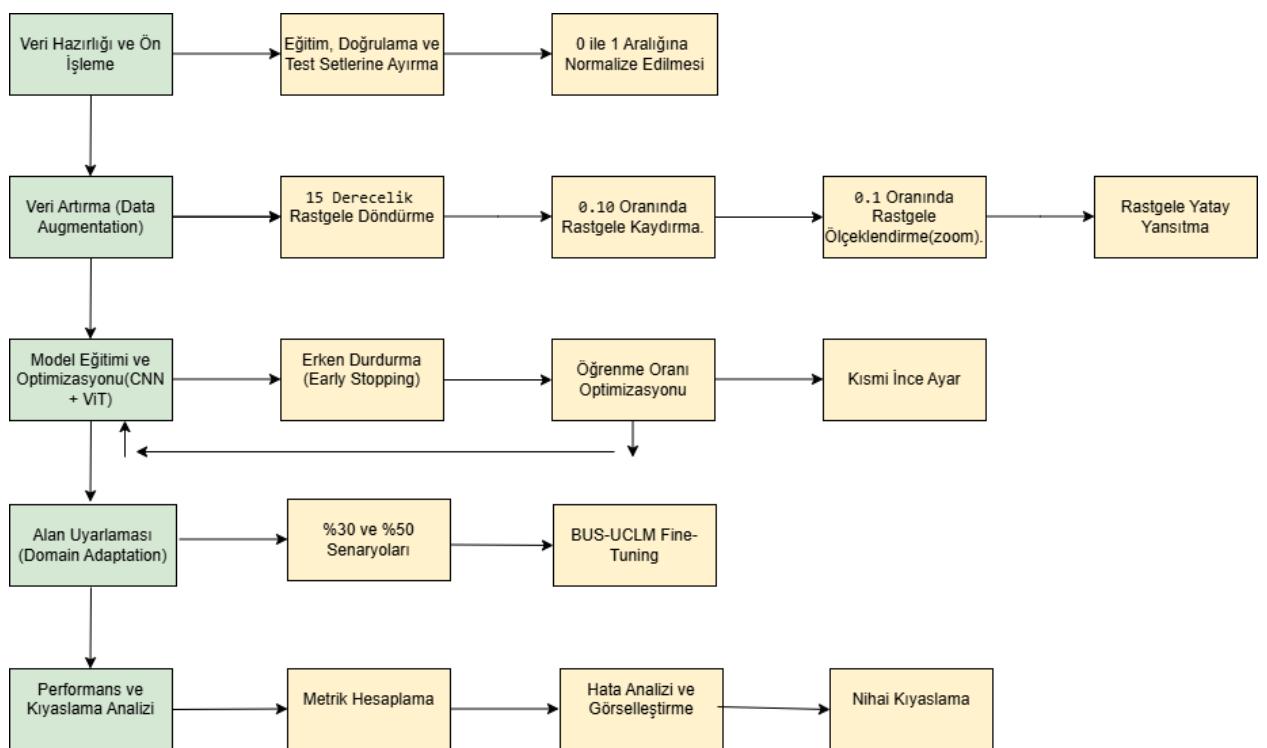
Proje, iki kişilik bir ekip tarafından yürütülecek ve toplam 16 hafta sürecek şekilde planlanmıştır. İş akışını, görev sürelerini ve teslim tarihlerini gösteren Gantt diyagramı Şekil 3.1'de verilmiştir.



Şekil 3.1 Gantt Diyagramı

4 SİSTEM TASARIMI

Bu bölümde, meme ultrasonu görüntülerinin sınıflandırılması için tasarlanan sistemin genel yapısı ve çalışma akışı sunulmaktadır. Şekil 4.1'de projenin başlangıçtan nihai sonuca kadar olan süreci özetleyen blok diyagramı yer almaktadır.



Şekil 4.1 Proje Blok Diyagramı

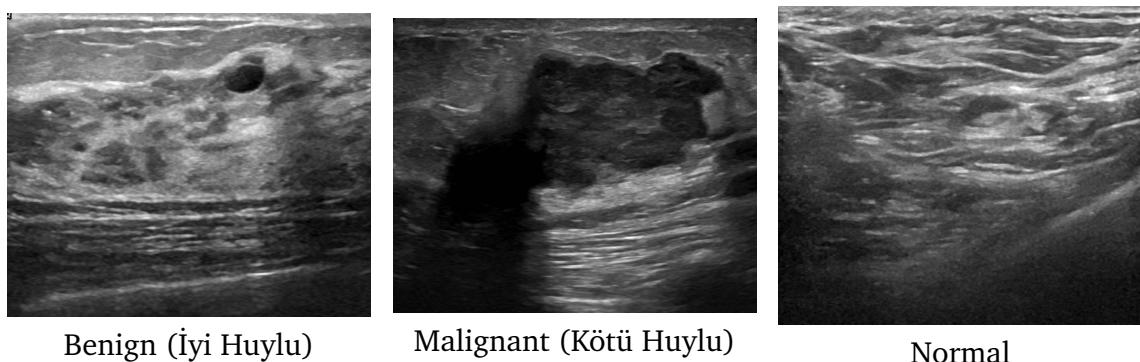
4.1 Materyal ve Veri Kümesi

4.1.1 BUSI (Breast Ultrasound Images) Veri Kümesi

Bu çalışmada ilk veri seti olarak, meme ultrason görüntülerini sınıflandırmak amacıyla BUSI (Breast Ultrasound Images) veri seti kullanılmıştır. BUSI, üç ana sınıfından oluşmaktadır: Benign (İyi Huylu), Malignant (Kötü Huylu) ve Normal. Veri seti toplam 780 görüntü içermekte olup, görüntüler PNG formatında saklanmaktadır. Şekil 4.2'de

veri setine ait örnek görseller yer almaktadır.

Şekil 4.2 Veri Setine Ait Örnek Görseller



Tablo 4.1 Veri Seti Hakkında Bilgi

Sınıf	Orijinal Görüntü Sayısı
Benign	437
Malignant	210
Normal	133
Toplam	780

4.1.2 Dengesizlik ve Veri Artırma Stratejisi

Veri setindeki sınıflar arasındaki belirgin dengesizlik, eğitilen derin öğrenme modellerinin belirli sınıflara karşı önyargılı öğrenmesini ve genellemeye yeteneğini kaybetmesini engellemek amacıyla Veri Artırma yöntemleri uygulanmıştır.

Uygulanan veri artırma işlemleri şunlardır:

- Rastgele döndürme
- Rastgele kaydırma
- Rastgele ölçeklendirme
- Yatay yansıtma

Bu işlemler sonucunda, veri seti başarıyla dengelenmiş ve model eğitiminde kullanılan toplam görüntü sayısı 7031'e yükseltilmiştir.

Tablo 4.2 Veri Seti Hakkında Bilgi

Sınıf	Veri Artırma Sonrası Görüntü Sayısı
Benign	2471
Malignant	2379
Normal	2181
Toplam	7031

4.1.3 BUS-UCLM Veri Kümesi

Bu çalışmada ikinci veri seti olarak, modellerin farklı klinik cihazlardan elde edilen görüntüler üzerindeki performansını ve alan adaptasyonu (domain adaptation) yeteneklerini değerlendirmek amacıyla BUS-UCLM veri seti kullanılmıştır. BUS-UCLM, lezyon segmentasyonu araştırmaları için özel olarak tasarlanmış olup 38 farklı hastadan elde edilen meme ultrason görüntülerinden oluşmaktadır. Veri seti; Benign (174), Malignant (90) ve Normal (419) olmak üzere üç ana sınıfa ayrılmış toplam 683 orijinal görüntü içermektedir. Veri setine ait orijinal sınıf dağılımı Tablo 4.3'te detaylandırılmıştır.

Tablo 4.3 BUS-UCLM Veri Seti Orijinal Sınıf Dağılımı

Sınıf	Orijinal Görüntü Sayısı
Benign	174
Malignant	90
Normal	419
Toplam	683

4.1.3.1 BUS-UCLM Dengesizlik ve Veri Artırma Stratejisi

BUS-UCLM veri setinin orijinal yapısında sınıflar dengeli dağılmamıştır. Bu durumu gidermek ve modellerin her sınıfı doğru oranda öğrenmesini sağlamak amacıyla, eğitim seti üzerinde kontrollü bir veri artırma uygulanmıştır.

Veri seti eğitim, doğrulama ve test olarak üç bölüme ayrılmıştır. Test ve doğrulama setleri, modellerin gerçek dünya performansını tarafsız bir şekilde yansıtılabilmesi için herhangi bir artırma işlemine tabi tutulmadan orijinal halleriyle korunmuştur. Eğitim setinde ise medikal doku bütünlüğünü bozmayan hafif dönüşümler içeren bir ImageDataGenerator konfigürasyonu kullanılmıştır. Veri artırma sürecinde şu teknikler uygulanmıştır: 15 dereceye kadar rastgele döndürme, %10 oranında yatay ve dikey kaydırma, hafif yakınlaştırma ve eğme işlemleri ile yatay eksende yansıtma.

Bu işlemler sonucunda eğitim setindeki Normal doku sayısı yaklaşık 3 katına, Benign doku sayısı 6 katına ve Malignant doku sayısı 9 katına çıkarılarak veri seti istatistiksel olarak dengelenmiştir. Gerçekleştirilen veri dağılımına ait son sayılar Tablo 4.4'te sunulmuştur.

Tablo 4.4 BUS-UCLM Transfer Öğrenme (TL) Veri Dağılımı

Sınıf	Eğitim (Augmented)	Doğrulama (Val)	Test	Toplam
Benign	725	26	27	778
Malignant	565	13	14	592
Normal	880	63	63	1006
Toplam	2170	102	104	2376

4.1.3.2 Alan Adaptasyonu (Domain Adaptation) Senaryoları

Alan Adaptasyonu, kaynak veri seti (BUSI) üzerinde eğitilen modellerin, farklı karakteristiklere sahip verilerine (BUS-UCLM) uyum sağlamasını amaçlar. Bu çalışmada, modellerin BUS-UCLM veri setindeki başarısını ölçmek için kısıtlı olan 683 orijinal görüntü kullanılarak iki farklı artırılmış senaryo kurgulanmıştır.

Bu senaryolarda temel amaç, eğitim sürecine dahil edilen veri miktarının modelin alan adaptasyonu (domain adaptation) başarısı üzerindeki etkisini gözlelemektir. İlk senaryoda, BUS-UCLM veri setinin yaklaşık %30'u seçilerek veri artırma teknikleriyle 648 görüntülü bir eğitim seti oluşturulmuş ve modellerin başarısı, 1516 görüntülü bir test kümesi üzerinde sınanmıştır. İkinci senaryoda ise verilerin %50'si eğitime dahil edilerek 1081 görüntülü bir eğitim seti hazırlanmış; model performansı ise yine artırılmış olan 1083 görüntülü test seti üzerinden ölçülmüştür. Her iki senaryoda da eğitim sürecini anlık olarak izleyebilmek için test verilerinin %20'si doğrulama seti olarak ayrılmıştır. Bu yaklaşım, modellerin BUSI veri setinden öğrendiği bilgileri, farklı bir kaynaktan gelen BUS-UCLM verilerine ne ölçüde genelleyebilebildiğinin denetlenmesine olanak tanımıştır. Senaryolara ait detaylı veri dağılım sayıları Tablo 4.5'te sunulmuştur.

Tablo 4.5 Alan Adaptasyonu Senaryoları Veri Dağılımı

Senaryo	Bölüm	Benign	Malignant	Normal	Toplam
%30 Senaryosu	Eğitim	221	133	294	648
%30 Senaryosu	Test	516	311	689	1516
%50 Senaryosu	Eğitim	368	222	491	1081
%50 Senaryosu	Test	369	222	492	1083

4.2 Metot

Bu projede kullanılan yöntem ve teknikler, temel olarak derin öğrenme tabanlı mimariler ve yaklaşılardan oluşmaktadır. İlk olarak çeşitli CNN tabanlı derin öğrenme mimarileri kullanılarak modeller oluşturulmuştur. CNN ya da bir diğer ifadeyle Evrişimli Sinir Ağları, tıbbi görüntüleri sınıflandırma da dahil olmak üzere görüntü işleme alanında yaygın olarak kullanılan bir derin öğrenme ağ mimarisidir. Ardışık ve katmanlı yapısı sayesinde ilk olarak konvolüsyon katmanına girdi olarak verilen görüntünün kenar ve desenler gibi yerel özelliklerini küçük boyutlu filtreler aracılığıyla algılanır ve özellik haritalarını çıkarılır. Daha sonra elde edilen bu özellik haritasının boyutu, en önemli özellikler korunarak küçültülür. Bu aşamada yapılan işlemler, modelin gürültülere karşı daha dayanıklı olmasını sağlamaktadır. Düzleştirme yani Flatten katmanında ise önceki katmanlardan gelen çok boyutlu özellik haritaları tek boyutlu vektöre dönüştürülür. Bu aşama bir sonraki katman olan Tam bağlantılı(Fully Connected) katmana geçiş için önemlidir. Son katman olan tam bağlantılı katmanda ise düzleştirilmiş özellik vektörleri kullanılarak yüksek seviyeli özellikler arasındaki ilişkiler kurulur ve nihai sınıflandırma kararı verilir. Bu aşamada Softmax aktivasyon fonksiyonu ile, önceki katmanlarda öğrenilen özellikler her bir sınıf için olasılık değerlerine dönüştürülür ve böylece sınıflandırma süreci tamamlanır.

4.2.1 Transfer Öğrenme

Bu çalışmada kullanılan veri kümesi yaklaşık 7000 adet png görüntüsünden oluşan büyük bir veri kümesidir. Büyük veri setleri üzerinde çalışırken eğitim aşaması oldukça önemli ve uzun soluklu bir işlemdir. Bu sebeple bu veri setinde kullanılan tüm CNN tabanlı mimarilerin eğitim aşamasında Transfer Learning yaklaşımından faydalansılmıştır. Transfer Learning, bir baz veri kümelerinin bir görev üzerinde eğitilerek bir baz ağı oluşturulması ve bu sayede öğrenilen temel özelliklerin başka bir görev üzerinde kullanılmasına dayanan bir model eğitim yaklaşımıdır. Kopyalanan ilk n katmanın ardından hedef ağıın geri kalan katmanları rastgele başlatılır ve hedef görevde doğru eğitilir. Gereken durumlarda yeni görevden gelen hatalar, kopyalanan taban özelliklere geri yayılarak bu özelliklerin yeni görevde göre fine-tune edilmesi tercih edilebilir veya aktarılan özellik katmanları dondurulmuş şekilde bırakılabilir. Bu da yeni görev üzerindeki eğitim sırasında bu katmanların değiştirilmeyecekleri anlamına gelir [9]. Bu çalışma bağlanmında hedef görev, meme ultrason görüntülerinden üç tümör sınıfını ayırt etme görevidir.

Transfer öğrenmede kaynak veri seti olarak büyük çoğunlukla ImageNet veri kümesi kullanılır. ImageNet özellikle derin öğrenme ve bilgisayarlı görü alanlarında kullanılan 1000 farklı sınıf ve milyonlarca görüntü içeren büyük ölçekli bir görsel veri setidir.

Bu veri kümesi sayesinde modeller kenar, köşe,doku ve renk gibi düşük seviye görsel özelliklerini öğrenir. Bu öğrenilmiş özellikler sonraki katmanlara aktarılırak hedef görev için eğitim aşamasında bir iş yükünün elimine edilmesini sağlar ve bu durum hem eğitim süresinin kısalmasına hem de sürecin verimliliğin artmasına katkıda bulunur. ImageNet'in kullanılması, görevden bağımsız olarak çoğu görüntü işleme problemlerinde faydalıdır.

Bu çalışmada transfer öğrenme stratejisi ile 6 farklı CNN tabanlı model eğitilmiştir. Bu modeller ResNet-50, DenseNet, EfficientNet, Xception, NasNet ve InceptionV3 mimarileridir.

4.2.2 ResNet Mimarisi

ResNet, önemli ölçüde daha derin ağların eğitimini kolaylaştırmak üzere Microsoft Research tarafından geliştirilen bir CNN mimarisidir. Pratikte, ağ derinleşikçe eğitimin zorlaştığı ve performansın düşüğü gözlemlenmiştir. Bu durum gradyan kaybı ve ağıın optimizasyonundaki zorluklar nedeniyle ortaya çıkar. Bu mimarideki yenilik, girdiyi birkaç katman ötesindeki çıktıya doğrudan ekleyen skip connections içeren residual blokları kullanılmıştır. Residual blokları, girdiye doğrudan hedefe dönüştürmek yerine kalıntıyı öğrenmeye çalışır. Kalıntı bloğu katmanlarının öğrenmesi için daha kolay bir hedef verir ve bu hedef girdiden ne kadar farklı olunması gerektiğini öğrenmektir. Ayrıca kalıntı blokları, ağıın derinliğinin artmasının performansı kötüleştirmeyeceğini garanti eder.Bu iki özellik sayesinde ResNet, modern derin öğrenme mimarilerinin temelini atmış ve 1000 kata kadar derinliğe sahip ağların dahi eğitilmesine olanak tanımıştir.

4.2.3 InceptionV3 Mimarisi

Projede test edilen mimarilerden bir diğeri ise InceptionV3 mimarisidir. Zamanla artan ağıın derinliği ve model boyutları hesaplama maliyetini önemli derecede etkileyen bir faktör haline gelmiştir. Bu probleme bir çözüm sağlamak üzere Google tarafından geliştirilen bu mimaride CNN'lerin hesaplama verimliliğini korurken model performansının artması hedeflenmiştir [10]. Bu hedef bağlamında parametre sayısının azaltılması hesaplama maliyetini düşüren etmenlerden biridir. Makalede önerilen “Factorizing Convolutions” fikri filtrelerin geometrik boyutunun azaltılarak örneğin 5x5 lik bir filtre yerine ardışık iki 3x3lük filtre kullanılması veya asimetrik konvolüsyonlara ayırtmayı sağlayarak hesaplama maliyetini düşürür. Aynı zamanda geleneksel CNN mimarilerinde her katmanda tek bir filtre boyutu kullanılır ve bu durum görüntülerin farklı özelliklerini yakalamada yetersiz kalabilir. Inception V3 mimarısında kullanılan Inception modülleri aynı anda farklı boyutlardaki filtreleri

uygular ve çıktıları birleştirir ve bu sayede ağ, uygun filtre boyutunu kendi öğrenir. Özette bu mimaride filtrelerin geometrik boyutunun azaltılması ve factorizing işlemi, ağın hesaplama yükünü ve parametrik yoğunluğunu azaltırken aynı zamanda temsil gücünde ciddi bir kayıp yaşanmamasını sağlamıştır.

4.2.4 DenseNet Mimarisi

Huang ve arkadaşları tarafından 2017 yılında sunulan DenseNet, yukarıda bahsedilen diğer mimariler gibi gradyan kaybolması ve artan parametre sayısı gibi sorunlara çözüm sunar. ResNet mimarisinde atlamlı bağıntılı yaklaşımını daha ileri bir noktaya taşır. Bu mimarinin en belirgin özelliği tüm katmanlar arasında doğrudan bağlantılar kurmasıdır yani her katmanın çıktısı, kendisinden sonraki tüm katmanların girdisine bağlanır denilebilir. Modele adını da veren bu “dense” yani yoğun bağlantı ağ genelinde kapsamlı bir bilgi akışı sağlar. Bu yoğun bağlantılar sayesinde gradyanlar ağın en alt katmanlarına kadar doğrudan bir yol bularak iletilir ve bu gradyan akışı ağın ilk katmanlarının bile güçlü bir hata sinyali olmasını sağlar. Her katman, kayıp fonksiyonundan gelen gradyanlara ve orijinal girdi sinyaline doğrudan erişime sahiptir. DenseNet, ağın en üstündeki tek bir sınıflandırıcı aracılığıyla tüm katmanlara örtük bir derin gözetim [11] sağlar. Bu durum, her katmana ayrı sınıflandırıcılar eklenen DSN (Deeply-Supervised Nets) yaklaşımına benzer ancak aynı kayıp fonksiyonu tüm katmanlar arasında paylaşıldığı için çok daha az karmaşıktır.

4.2.5 EfficientNet Mimarisi

Google tarafından geliştirilen EfficientNet mimarisi, derin öğrenme modellerinin performansını artırmaya çalışırken hesaplama maliyetlerini azaltmayı hedefler. Geleneksel yaklaşılarda, model performansını artırmak için derinlik, genişlik veya çözünürlük gibi üç boyuttan biri sırayla artırılıyordu. Ancak EfficientNet, bunların hepsini aynı anda, tek bir bileşen ölçeklendirmesi (Compound Scaling) kullanarak optimize ederek gerçekleştirir. Bu bileşen ölçeklendirme yaklaşımı sayesinde model, belirli bir hesaplama bütçesi içinde en iyi doğruluğu elde eder.[12] Model, kaynakların sınırlı olduğu tıbbi görüntüleme projeleri için idealdir (örneğin, mobil cihazlar veya sınırlı GPU gücü). EfficientNet ailesi küçükten büyüğe doğru sıralanacak şekilde tasarlandığından, veri setinin boyutuna ve hesaplama kısıtlamalarına göre tercih edilecek bir model sunar.

4.2.6 NASNet Mimarisi

NASNet (Neural Architecture Search Network), Google Brain tarafından geliştirilen ve Otomatik Makine Öğrenimi alanının öncülerinden olan bir mimaridir. Diğer

CNN modelleri uzmanlar tarafından tasarlanırken, NASNet'in mimarisi bir arama algoritması (RNN) tarafından otomatik olarak tasarlanmıştır[13].

Bu arama algoritması, en iyi performansı verecek olan hücre yapılarını öğrenir. Bu hücreler daha sonra yiğinlanarak genel ağı oluşturur. NASNet'in temel hücre yapıları, ImageNet gibi büyük veri setlerinde yüksek doğruluk elde etmek için optimize edilmiştir. Bu, modelin tıbbi görüntülerdeki karmaşık ve az rastlanan desenleri bile yakalama yeteneğini artırır, ancak arama maliyeti ve parametre sayısı diğer modellere göre daha yüksek olabilmektedir.

4.2.7 Xception Mimarisi

Xception (Extreme Inception), François Chollet tarafından geliştirilen ve Inception mimarisinin radikal bir evrimi olarak sunulmuştur. Bu mimari, temel olarak geleneksel konvolüsyonel işlemleri tamamen terk ederek, Derinlik Ayrılabilir Konvolüsyon kavramını ağır ana yapı taşı haline getirir. Xception'in temel amacı, CNN'lerin hesaplama verimliliğini korurken model performansının artmasıdır.

Geleneksel konvolüsyon hem uzamsal hem de kanal özelliklerini aynı anda eşlerken, Xception bu işlemi iki ayrı aşamaya böler: Önce her bir giriş kanalını ayrı ayrı işleyen Derinlik Konvolüsyonu, ardından 1×1 'lik konvolüsyonlarla tüm çıktı kanallarını birleştiren Noktasal Konvolüsyon. Bu ayrıştırma, ağır hesaplama yükünü ve parametre sayısını önemli ölçüde azaltır. Xception, bu verimli yaklaşımı sayesinde ResNet ve DenseNet gibi derin ağlarla rekabet edebilecek yüksek performans sunarak, özellikle büyük görüntü setlerinde eğitim sürecinin verimliliğini artırmıştır[14].

4.2.8 Vision Transformer

CNN modellerine göre daha güncel bir model olan Transformer tabanlı Vision Tranformer mimarisi de çalışmada kullanılabilecek potansiyel çözüm yaklaşımlarından biridir. Transformerlar, doğal dil işlemede kullanılan self-attention tabanlı mimarilerdir [15]. Self attention mekanizması, CNN'lerden farklı olarak görüntünün her bölgesi için diğer tüm bölgelerle olan ilişkisini kontrol eder ve odak noktalarını buna göre belirler. Vision Transformer ise bu yaklaşımından faydalananarak görüntü işleme için tasarlanmış bir transformer modelidir. Temel prensip, görüntüyü NLP'deki gibi token dizisi olarak ele almaktır. İlk olarak girdi görüntüsü, sabit boyutlu küçük kare patchlere bölünür ve embedding işlemiyle her parça bir boyutlu vektörlere dönüştürülür. Ardından positional encoding işlemi yapılarak parçaların görüntü içindeki konum bilgileri sağlanır. Tüm bu bilgilerle elde edilen dizi, transformer encoder bileşenine aktarılır. Burada self- attention mekanizması ve ardından MLP

bloğu ile iki ana katmanlı yapıdan geçen girdi verisi ardışık olarak işlenerek global bağımlılıklar ve yüksek seviyeli özellikler öğrenilir. Son encoder bloğunun çıkışı ise sınıflandırma başlığına iletilerek nihai tahmin elde edilir.

Vision transformer modelleri, performans ve verimlilik açısından değerlendirildiğinde ise ResNet tabanlı modeller ile karşılaştırıldığında daha üstün bir performans göstermekle birlikte bunu yaparken 2-4 kat daha az hesaplama kaynağı kullanmaktadır. Bu da bellek açısından da verimli olduğunu göstermektedir [15].

5 DENEYSEL SONUÇLAR

Raporun bu bölümünde, sistem tasarımı kısmında açıklanan CNN modelleri, ilk aşamada BUSI veri seti üzerinde farklı öğrenme oranlarında eğitilip test edilmiş ve sonuçlar değerlendirilmiştir. Üç farklı öğrenme oranı üzerinden yapılan hiperparametre optimizasyonu işlemi sonucunda modellerin test kümesi üzerindeki başarısı; accuracy, f1 score, precision ve recall metriklerine göre yorumlanmıştır ve en başarılı modeller kaydedilmiştir. İkinci aşamada ise kaydedilen modeller Domain Adaptation yaklaşımı ile farklı veri setleri üzerinde fine tune edilip test edilmiştir.

5.1 Performans Analizi

5.1.1 BUSI Veri Seti Deney Sonuçları

Bu bölümde, tümör sınıflandırmasında çeşitli CNN modellerinin etkinliğini ölçmek amacıyla; sistem tasarımı kısmında belirlenen altı farklı derin öğrenme mimarisinin BUSI veri seti üzerindeki eğitim sonuçları yer almaktadır. Bu aşamada amaç, farklı mimarilerin ultrason görüntülerindeki öznitelikleri ne derece başarıyla ayırt edebildiğini saptamaktır. Bu doğrultuda yapılan analizler; EfficientNet, InceptionV3, DenseNet, ResNet-50, NasNetLarge ve Xception olmak üzere 6 mimari üzerine kurulmuştur. Eğitimlerde üç farklı öğrenme oranı test edilerek modellerin yakınsama hızları ve en kararlı oldukları çalışma noktaları tespit edilmiştir. Modeller sadece doğruluk bazında değil; hassasiyet, kesinlik ve F1-skor metrikleri üzerinden de değerlendirilmiştir. Eğitim süreci, tüm modellerde transfer öğrenme yöntemiyle ImageNet üzerinden gerçekleştirilmiştir. Eğitim süresince 7.031 adet ultrason görüntüsü; %70 eğitim, %15 validasyon ve %15 test olarak bölümlenerek kullanılmıştır. Elde edilen bulgular; sayısal performans tabloları, öğrenme eğrileri ve modellerin hangi sınıflarda hata yapma eğiliminde olduğunu gösteren karışıklık matrisleri aracılığıyla analiz edilmiştir. Aşağıdaki alt başlıklarda, her bir modelin farklı öğrenme oranlarındaki performansı ve elde edilen en optimum sonuçlar detaylandırılmaktadır.

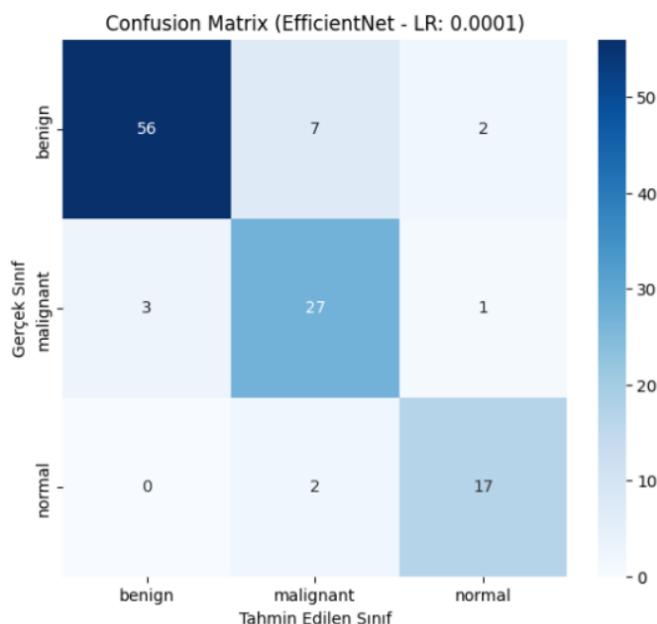
5.1.1.1 EfficientNet Modeli Deney Sonuçları

EfficientNet modeliyle yapılan eğitimin ardından modelin test kümesi üzerindeki başarı metrikleri aşağıda listelenmiştir.

Tablo 5.1 EfficientNet modelinin öğrenme oranına bağlı performans metrikleri

Model/Output	Accuracy	Recall	Precision	F1-Score
EfficientNet (LR=10 ⁻³)	0,8609	0,8609	0,9	0,88
EfficientNet (LR=10 ⁻⁴)	0,8696	0,8348	0,9057	0,8688
EfficientNet (LR=10 ⁻⁵)	0,7913	0,6696	0,837	0,744

Sınıflandırma başarı performansını daha iyi yorumlayabilmek adına karışıklık matrisleri de aşağıdaki gibi görselleştirilmiştir.



Şekil 5.1 EfficientNet 10⁻⁴ Öğrenme Oranı Karışıklık Matrisi

Değerlendirme metrikleri incelendiğinde öncelikle modelin 3 öğrenme oranında da dengeli bir performans sergilediği görülür. Metrikler birlikte ele alındığında ise modelin başarılı performansını 10⁻⁴ öğrenme oranında gösterdiği görülmektedir. Tablodan görüldüğü gibi en yüksek accuracy ve precision değerleri %86,96 ve %90,57 ile 10⁻⁴ öğrenme oranı sonuçlarına aittir. Bu da tümörler sınıflandırılırken özellikle precision üzerinden ele alındığında malignant sınıfına ait tümörün yüksek oranla doğru sınıflandırıldığını gösterir.

Karışıklık matrisleri incelendiğinde ise 10⁻³ ve 10⁻⁴ öğrenme oranlarında modellerin genel olarak özellikle benign ve normal dokularda benzer ve doğru tahminler yaptığı söylenebilir. Fakat malignant sınıfına ait test kümesindeki 31 tümör dokusunun 27 tanesini doğru sınıflandıran model 10⁻⁴ öğrenme oranında sahip modeldir. Bu sonuç

da değerlendirme metriklerini inceleyerek verdigimiz en iyi model kararının doğru olduğunu kanitlar niteliktedir. Gerçekte benign sınıfına ait olup malignant olarak yanlış değerlendirilen 7 adet doku olduğu görülmektedir. Bu false-positive durumu bu veri seti ve örnek sayısı bağlamında kabul edilebilir bir seviyededir.

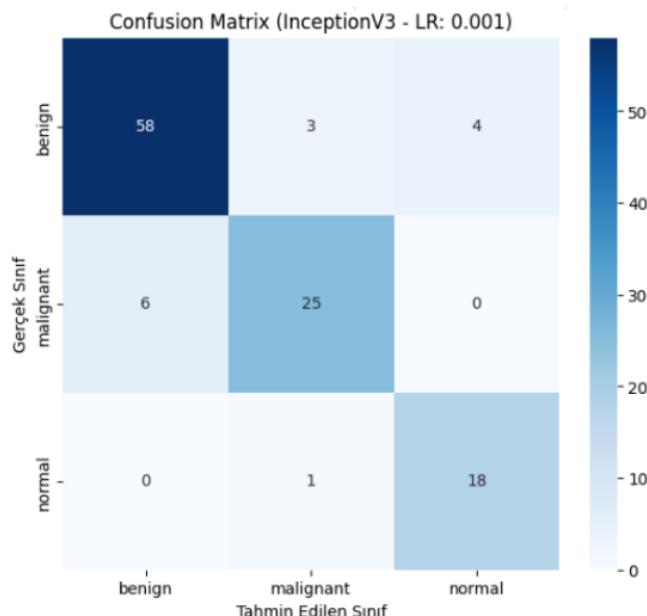
5.1.1.2 InceptionV3 Modeli Deney Sonuçları

InceptionV3 modeliyle yapılan eğitimin ardından modelin test kümesi üzerindeki başarı metrikleri aşağıda listelenmiştir.

Tablo 5.2 InceptionV3 modelinin öğrenme oranına bağlı performans metrikleri

Model/Output	Accuracy	Recall	Precision	F1-Score
InceptionV3 ($LR=10^{-3}$)	0,8783	0,8696	0,885	0,8772
InceptionV3 ($LR=10^{-4}$)	0,8783	0,8174	0,9216	0,8664
InceptionV3 ($LR=10^{-5}$)	0,8783	0,7478	0,9247	0,8269

Sınıflandırma başarı performansını daha iyi yorumlayabilmek adına karışıklık matrisleri de aşağıdaki gibi görselleştirilmiştir.



Şekil 5.2 InceptionV3 10^{-3} Öğrenme Oranı Karışıklık Matrisi

Değerlendirme metrikleri incelendiğinde ilk göze çarpan üç farklı öğrenme oranı için de modellerin aynı accuracy değerine sahip olduğunu söyleyebiliriz. 3 model de test kümesindeki doğru tahmin edilen görüntü sayısı aynı olduğundan bu sonuç ortaya çıkmıştır. Diğer metriklere bakıldığında Recall metriğinin öğrenme oranı azaldıkça azaldığı görülmektedir. En yüksek recall değeri 10^{-3} öğrenme oranlı modelde elde edilmiştir. Bu sonuç, modelin gerçek pozitifleri yakalamada iyi olduğunu yani kanserli dokuları

ayırt etmede başarılı olduğunu gösterir. Precision değeri en yüksek 10^{-5} öğrenme oranına sahip üçüncü modeldedir.F1 score değerleri ise ilk iki modelde yakın değerlere sahiptir. Tüm bunlar birlikte değerlendirildiğinde en dengeli ve başarılı modelin 10^{-3} öğrenme oranlı model olduğu yorumu yapmaktadır.

Karışıklık matrislerine bakıldığından ise malignant ve normal dokular için en çok sayıda doğru tahmini 1. modelin yaptığı görülmektedir. Fakat benign yani iyi huylu tümör dokularında bazı durumlarda tedbirli davranışın benign dokuları, malignant olarak sınıflandırılmış.Benign dokuların sınıflandırılmasında en çok doğru tahmini yapan model ise 10^{-5} öğrenme oranına sahip olan üçüncü modeldir. Fakat bu model malign dokuları tahminlemede ilk model kadar başarılı olmamıştır. Tüm matrisler değerlendirildiğinde kritik olan faktör kanserli dokuları doğru tahminlemek olduğundan en iyi model olarak 10^{-3} öğrenme oranına sahip olan model seçilmiştir.

5.1.1.3 DenseNet Modeli Deney Sonuçları

DenseNet modeliyle yapılan eğitimin ardından modelin test kümesi üzerindeki başarı metrikleri aşağıda listelenmiştir.

Tablo 5.3 DenseNet modelinin öğrenme oranına bağlı performans metrikleri

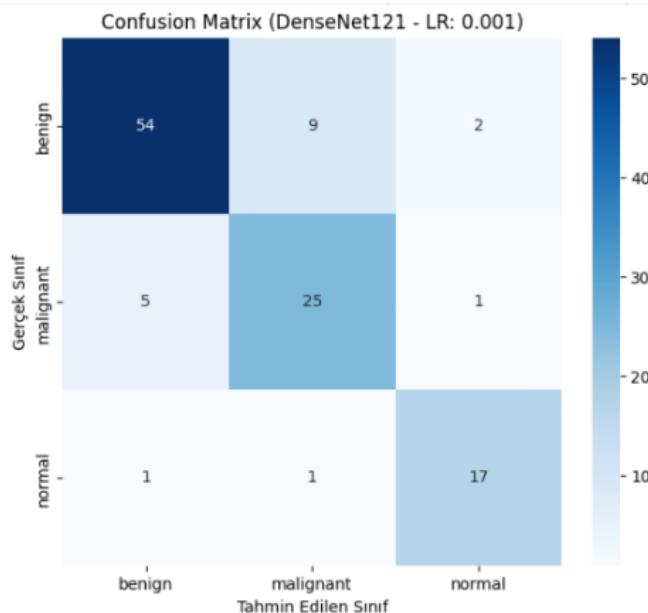
Model/Output	Accuracy	Recall	Precision	F1-Score
DenseNet (LR= 10^{-3})	0,8348	0,7892	0,8515	0,8192
DenseNet (LR= 10^{-4})	0,8174	0,7617	0,8483	0,8027
DenseNet (LR= 10^{-5})	0,7565	0,5914	0,7871	0,6754

Sınıflandırma başarı performansını daha iyi yorumlayabilmek adına karışıklık matrisleri de aşağıdaki gibi görselleştirilmiştir.

DenseNet modelleri için metrik tablosuna bakıldığından 10^{-3} öğrenme oranıyla eğitilen birinci modelin tüm metrikler bazında en iyi sonucu veren model olduğu istatiksel anlamda net bir şekilde görülmektedir. %83,48 accuracy, %78,92 recall, %85,15 precision ve %81,92 f1 score değerleri ve öğrenme grafiği birlikte ele alındığında modelin ideal sonuca yakınsayan bir davranış sergilemektedir.

Bu model bazında öğrenme oranını düşürmek, model performansında da gözle görülür bir kötüleşmeye sebep olmuştur. Öğrenme oranı 10^{-5} 'e çıkarıldığında accuracy değeri %75.65'e, recall değeri ise %59.14'e gerilemiştir. Bu durum modelin underfitting yani yetersiz öğrenmeye uğramasından kaynaklanabileceği gibi epoch sayısının yetersiz kalması ve öğrenme eğrisinde yerel minimum problemine takılmasından kaynaklanabilir.

Karışıklık matrislerine bakıldığından ise tüm sınıflar bazında en doğru tahminlerin ilk



Şekil 5.3 DenseNet 10^{-3} Öğrenme Oranı Karışıklık Matrisi

modelde yapıldığı görülmektedir. Özellikle malignant sınıfına ait test kümesindeki görüntülerde 31 görselden 25'i doğru tahmin edilerek en yüksek başarı elde edilmiştir. Diğer benign ve normal sınıflarında da %80 üzerinde doğruluk gözlemlenmiştir. Bu da sınıf dengesizliğine rağmen modelin oldukça başarılı tahminler yaptığı ve 10^{-3} öğrenme oranının bu model için optimum çalışma noktası olduğu kanısına varmayı sağlamıştır.

5.1.1.4 ResNet-50 Modeli Deney Sonuçları

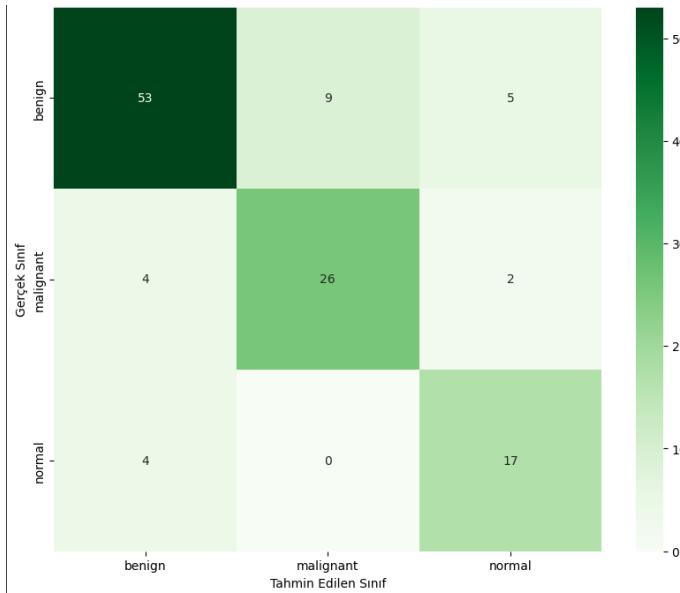
ResNet-50 modeliyle yapılan eğitimin ardından modelin test kümesi üzerindeki başarı metrikleri aşağıda listelenmiştir.

Tablo 5.4 ResNet-50 modelinin öğrenme oranına bağlı performans metrikleri

Model/Output	Accuracy	Recall	Precision	F1-Score
ResNet-50 (LR= 10^{-3})	0,7826	0,7826	0,7843	0,7745
ResNet-50 (LR= 10^{-4})	0,7417	0,7417	0,7461	0,7319
ResNet-50 (LR= 10^{-5})	0,8	0,798	0,7991	0,7943

Sınıflandırma başarı performansını daha iyi yorumlayabilmek adına karışıklık matrisleri de aşağıdaki gibi görselleştirilmiştir.

ResNet-50 modelinin metrikleri incelendiğinde, üç farklı öğrenme oranında da birbirine yakın ve kararlı bir performans sergilediği görülmektedir. Metrikler bütünsel olarak ele alındığında, modelin en başarılı performansını %80 accuracy ve %79,91 precision değerleri ile 10^{-5} öğrenme oranında sergilediği görülmektedir. Bu sonuç,



Şekil 5.4 ResNet-50 10^{-5} Öğrenme Oranı Karışıklık Matrisi

daha düşük öğrenme oranının modelin BUSI veri setindeki karmaşık öznitelikleri daha derinlemesine öğrenmesine ve ağırlık güncellemlerini daha hassas yapmasına olanak tanadığını göstermektedir. Karışıklık matrisleri incelendiğinde, 10^{-3} ve 10^{-5} öğrenme oranlarında modellerin genel olarak benign ve normal dokularda oldukça yüksek doğru tahmin oranlarına ulaştığı söylenebilir. Özellikle 10^{-5} öğrenme oranına sahip modelde, test kümelerindeki sınıfların dengeli bir şekilde dağıldığı ve yanlış pozitif oranının tıbbi teşhis açısından kabul edilebilir bir seviyede tutulduğu görülmektedir. 10^{-4} öğrenme oranında ise metriklerde küçük bir düşüş yaşansa da modelin genel başarısı %74 bandının üzerinde kalmıştır. Tüm matrisler ve değerlendirme metrikleri birlikte analiz edildiğinde, kritik olan faktörün hem yüksek doğruluk hem de sınıflar arası denge olduğu görülmektedir. Bu bağlamda, %79,43'lük F1-score değeriyle 10^{-5} öğrenme oranına sahip olan model, BUSI veri seti için en optimum ve güvenilir model olarak seçilmiştir.

5.1.1.5 NasNetLarge Modeli Deney Sonuçları

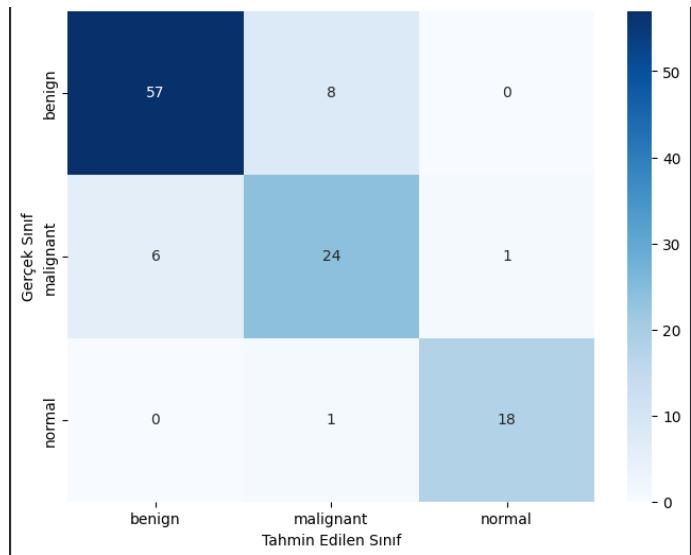
NasNetLarge modeliyle yapılan eğitimin ardından modelin test kümeleri üzerindeki başarı metrikleri aşağıda listelenmiştir.

Tablo 5.5 NasNetLarge modelinin öğrenme oranına bağlı performans metrikleri

Model/Output	Accuracy	Recall	Precision	F1-Score
NasNetLarge ($LR=10^{-3}$)	0,8522	0,8779	0,8380	0,8529
NasNetLarge ($LR=10^{-4}$)	0,8348	0,8564	0,8154	0,8325
NasNetLarge ($LR=10^{-5}$)	0,8	0,8111	0,7839	0,7296

Sınıflandırma başarı performansını daha iyi yorumlayabilmek adına karışıklık

matrisleri de aşağıdaki gibi görselleştirilmiştir.



Şekil 5.5 NasNetLarge 10^{-3} Öğrenme Oranı Karışıklık Matrisi

NasNetLarge modeli için metrikler incelediğinde, 10^{-3} öğrenme oranı ile eğitilen ilk modelin tüm performans kriterleri bazında en yüksek başarıyı elde ettiğini görülmektedir. %85,22 accuracy, %87,79 recall ve %85,29 F1-score değerleri, bu mimarinin BUSI veri setindeki doku özelliklerini öğrenmede oldukça başarılı olduğunu göstermektedir. Özellikle recall değerinin %87,79 gibi yüksek bir seviyede olması, modelin gerçek pozitif vakaları yakalama gücünün yüksek olduğunu ve kanserli dokuları saptamada oldukça başarılı bir grafik çizdiğini göstermektedir. NasNetLarge modeli için öğrenme oranını düşürmek, performansın kademeli olarak azalmasına neden olmuştur. Öğrenme oranı 10^{-5} seviyesine gerilediğinde accuracy değeri %80,00'e, F1-score ise %72,96'ya düşmüştür. Bu durum, NasNetLarge gibi çok büyük ve karmaşık parametre yapısına sahip modellerin, çok düşük öğrenme oranlarında hedef sonuca yakınsamakta yavaş kaldığını veya eğitim süresince optimum ağırlıklara ulaşamadığını düşündürmektedir. Karışıklık matrisleri değerlendirildiğinde, 10^{-3} öğrenme oranına sahip modelin özellikle malignant sınıfına ait görüntülerde yüksek bir doğru tahmin başarısı sergilediği görülmektedir. Normal dokuların ayırt edilmesinde de tutarlı sonuçlar veren model, sınıf dengesizliğine rağmen genel hata payını düşük tutmayı başarmıştır. Tüm veriler ışığında, NasNetLarge mimarisi için BUSI veri setinde en dengeli ve başarılı tahminlerin 10^{-3} öğrenme oranı ile elde edildiği sonucuna varılmıştır.

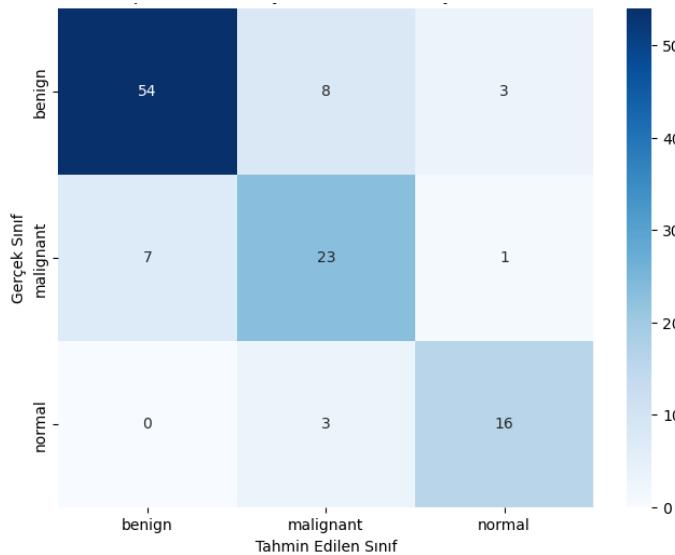
5.1.1.6 Xception Modeli Deney Sonuçları

Xception modeliyle yapılan eğitimin ardından modelin test kümesi üzerindeki başarı metrikleri aşağıda listelenmiştir.

Tablo 5.6 Xception modelinin öğrenme oranına bağlı performans metrikleri

Model/Output	Accuracy	Recall	Precision	F1-Score
Xception ($LR=10^{-3}$)	0,8	0,8178	0,7683	0,787
Xception ($LR=10^{-4}$)	0,7739	0,7889	0,7463	0,7581
Xception ($LR=10^{-5}$)	0,7217	0,7637	0,7126	0,7173

Sınıflandırma başarı performansını daha iyi yorumlayabilmek adına karışıklık matrisleri de aşağıdaki gibi görselleştirilmiştir.



Şekil 5.6 Xception 10^{-3} Öğrenme Oranı Karışıklık Matrisi

Değerlendirme metrikleri incelendiğinde, Xception modelinde öğrenme oranı düşükçe modelin genel başarısının da azaldığı net bir şekilde görülmektedir. 10^{-3} öğrenme oranında %80 gibi başarılı bir sonuç alan model, öğrenme oranı 10^{-5} 'e indirildiğinde %72,17 doğruluğa kadar gerilemiştir. Bu durum, öğrenme oranı çok düşük seçildiğinde modelin verideki detayları tam olarak kavrayamadan eğitimin sona erdiğini göstermektedir. Ancak dikkat çeken bir nokta; genel doğruluk düşse bile modelin kanserli dokuları yakalama oranı %76 seviyelerinde kalarak belirli bir başarısını korumuştur. Karışıklık matrislerine bakıldığından, ilk modelin (10^{-3}) hem iyi huylu hem de normal dokuları ayırt etmede oldukça güvenilir olduğu söylenebilir. Her ne kadar kötü huylu tümörlerin bir kısmında yanlış tahminler yapılmış olsa da, precision ve recall değerleri arasındaki dengeye bakıldığından en ideal ve kullanışlı sonuçların 10^{-3} öğrenme oranında elde edildiği görülmektedir.

5.1.2 BUS-UCLM Veri Seti Deney Sonuçları

Bu bölümde, modellerin hem farklı bir veri kaynağı üzerindeki başarısını ölçmek amacıyla hem de alan uyarlaması yaklaşımıyla elde edilen sonuçları karşılaştırmak

için BUS-UCLM veri seti kullanılarak gerçekleştirilen transfer öğrenme eğitimlerinin sonuçları ele alınmıştır. BUSI veri setinde uygulandığı gibi burada da hiperparametre optimizasyonu yapılmış ve modellerin farklı öğrenme oranlarındaki başarısı karşılaştırılmıştır. Modellerin performansı aşağıdaki tablolarda listelenmiştir.

Tablo 5.7 EfficientNet modelinin UCLM veri seti üzerinde öğrenme oranına bağlı performans metrikleri

Model/Output	Accuracy	Recall	Precision	F1-Score
EfficientNet (LR= 10^{-3})	0,8173	0,7885	0,8454	0,8159
EfficientNet (LR= 10^{-4})	0,7788	0,7019	0,8202	0,7565
EfficientNet (LR= 10^{-5})	0,6635	0,4904	0,75	0,593

Tablo 5.8 InceptionV3 modelinin UCLM veri seti üzerinde öğrenme oranına bağlı performans metrikleri

Model/Output	Accuracy	Recall	Precision	F1-Score
InceptionV3 (LR= 10^{-3})	0,8269	0,8077	0,8571	0,8317
InceptionV3 (LR= 10^{-4})	0,8269	0,75	0,8298	0,7879
InceptionV3 (LR= 10^{-5})	0,6731	0,4904	0,8095	0,6108

Tablo 5.9 DenseNet modelinin UCLM veri seti üzerinde öğrenme oranına bağlı performans metrikleri

Model/Output	Accuracy	Recall	Precision	F1-Score
DenseNet (LR= 10^{-3})	0,75	0,7212	0,8152	0,7653
DenseNet (LR= 10^{-4})	0,7692	0,7115	0,7872	0,7475
DenseNet (LR= 10^{-5})	0,6635	0,4808	0,7143	0,5747

Tablo 5.10 ResNet-50 modelinin UCLM veri seti üzerinde öğrenme oranına bağlı performans metrikleri

Model/Output	Accuracy	Recall	Precision	F1-Score
ResNet-50 (LR= 10^{-3})	0,7308	0,73	0,73	0,71
ResNet-50 (LR= 10^{-4})	0,7404	0,74	0,77	0,74
ResNet-50 (LR= 10^{-5})	0,7802	0,78	0,784	0,7345

Tablo 5.11 NasNetLarge modelinin UCLM veri seti üzerinde öğrenme oranına bağlı performans metrikleri

Model/Output	Accuracy	Recall	Precision	F1-Score
NasNetLarge ($LR=10^{-3}$)	0,7596	0,76	0,78	0,73
NasNetLarge ($LR=10^{-4}$)	0,75	0,75	0,75	0,72
NasNetLarge ($LR=10^{-5}$)	0,7596	0,7596	0,7476	0,7489

Tablo 5.12 Xception modelinin UCLM veri seti üzerinde öğrenme oranına bağlı performans metrikleri

Model/Output	Accuracy	Recall	Precision	F1-Score
Xception ($LR=10^{-3}$)	0,875	0,88	0,88	0,87
Xception ($LR=10^{-4}$)	0,8462	0,8462	0,8474	0,8464
Xception ($LR=10^{-5}$)	0,8462	0,8558	0,8576	0,84

BUS-UCLM veri seti orijinalinde 683 görüntüden oluşmaktadır. Ancak, derin öğrenme modellerinin daha fazla veri görmesi ve sınıflar arasındaki dengesizliğin giderilmesi amacıyla veri artırma ve düzenleme işlemleri uygulanmıştır. Yapılan çalışmalar sonucunda veri seti toplamda 2.390 görüntüye çıkarılmıştır.

Tüm modeller ImageNet ağırlıkları ile başlatılarak Transfer Learning yöntemiyle BUS-UCLM veri seti üzerinde yeniden eğitilmiştir. BUS-UCLM veri seti sonuçlarına bakıldığından, hiperparametre optimizasyonu işlemleri sonucunda öğrenme oranı düştükçe modellerin genelinde performans metriklerinde düşüş ya da durağan davranış gözlemlenmiştir. Xception modelinin %87,5 doğruluk oranıyla diğerlerinden bir adım önde olduğu görülmektedir. Bu model, hem sağlıklı hem de hastalıklı dokuları birbirinden ayırmada oldukça dengeli ve güvenilir sonuçlar vermiştir. Onu yakından takip eden InceptionV3 ise %82,69 başarı oranıyla ikinci sırada yer almıştır. Efficient modeli özellikle 10^{-3} öğrenme oranındaki %81,73 doğruluk oranıyla başarılı bir performans sergilemiştir. Dikkat çeken bir diğer nokta ise ResNet modelinin başarısıdır; bu model diğerlerine göre çok daha yavaş ve hassas bir öğrenme yolu izleyerek en iyi sonucuna ulaşmıştır. Bu durum, farklı model yapılarının veriyi öğrenmek için farklı hızlara ihtiyaç duyduğunu kanıtladır.

Eğitimde kullandığımız resimlerin dağılımı da sonuçlar üzerinde önemli bir rol oynamıştır. Özellikle normal olarak sınıflandırılan sağlıklı doku resimlerinin sayısının fazla olması, modellerin sağlıklı bölgeleri tanıma becerisini geliştirmiştir.

Genel olarak modellerin BUS-UCLM üzerindeki performansı BUSI datası kadar başarılı

olmasa da oldukça iyi sonuçlar vermiştir. Bunun en büyük sebebi veri setlerindeki ultrason görüntülerinin sayısı ve çeşitliliğidir.

5.1.3 Alan Uyarlaması Yaklaşımı Deney Sonuçları

Çalışmanın bu bölümünde transfer öğrenmenin bir alt dalı olan domain adaptation yani alan uyarlaması yaklaşımından faydalانılmıştır. Bu stratejide, daha önceki aşamalarda BUSI veri seti ile eğitilmiş modeller, BUS-UCLM isimli ikinci bir veri setinde, hedef veri seti olarak uyarlanmış ve test edilmiştir. Buradaki en önemli amaç, BUSI görüntüleri ile eğitilmiş modellerin, BUS-UCLM veri setiyle alan uyarlaması uygulandığında sadece transfer eğitimle eğitilmiş modellere göre nasıl bir başarı ortaya koyduğunu gözlemlemek. Deneyler, hedef veri setinin kullanılma oranına göre iki farklı senaryo üzerinden gerçekleştirılmıştır. İlk senaryoda verinin %30'u, eğitim, %14'ü validasyon ve %56'sı test olarak ayrılmıştır. İkinci senaryoda ise eğitim oranı %50'ye çıkarılmış, validasyon %10 ve test oranı %40 olarak belirlenmiştir. Elde edilen performans metrikleri Tablo 5.13 ve Tablo 5.14'de sunulmuştur. Önceki aşamalarda elde edilen 6 farklı CNN modellerinden en iyileri kaydedilerek, domain adaptation işleminde source domain olarak kullanılmıştır.

Tablo 5.13 %30 eğitim kümesi ile alan uyarlaması sonuçları

Model/Output	Accuracy	Recall	Precision	F1-Score
EfficientNet	0.8839	0.8839	0.8871	0.8845
DenseNet	0.7825	0.7644	0.8042	0.7830
InceptionV3	0.7397	0.7166	0.7539	0.7348
ResNet	0.8433	0.8290	0.8315	0.8302
NasNet	0.6763	0.6408	0.6477	0.6442
Xception	0.7185	0.6954	0.7022	0.6988

Tablo 5.14 %50 eğitim kümesi ile alan uyarlaması sonuçları

Model/Output	Accuracy	Recall	Precision	F1-Score
EfficientNet	0,926	0,931	0,887	0,9030
DenseNet	0,8387	0,8306	0,8502	0,8403
InceptionV3	0,7949	0,7811	0,8014	0,7911
ResNet	0,8675	0,841	0,8745	0,8537
NasNet	0,6993	0,6574	0,6799	0,6648
Xception	0,7166	0,698	0,7245	0,7092

Tablo 5.13'te sunulan %30 eğitim verisi senaryosunda, modellerin kısıtlı hedef veriyle yeni bir alana uyum sağlama yetenekleri test edilmiştir. Bu senaryoda ResNet-50 modeli, öznitelik aktarımını en verimli gerçekleştiren yapı olarak öne çıkmış ve en yüksek doğruluk oranına ulaşmıştır.

Tablo 5.14'de yer alan %50 eğitim verisi senaryosunda ise veri miktarındaki artışın tüm modellerde performans iyileşmesine katkı sağladığı görülmektedir. Özellikle EfficientNet modelinin veri miktarı arttığında %92,6 doğruluk oranıyla zirveye yerleşmesi, bu mimarinin alan uyarlaması sürecinde daha geniş veri kümeleriyle yüksek genelleme kapasitesine ulaştığını kanıtlamaktadır. Genel toplamda, alan uyarlaması stratejisinin özellikle ResNet gibi modellerde klasik transfer öğrenme sonuçlarını geride bırakması, ultrason görüntülerine özgü öğrenilmiş bilgilerin farklı klinik veri setlerinde kullanılabilirliğini doğrulamaktadır.

5.1.4 Vision Transformer (ViT) Tabanlı Mimarilerin Performans Analizi

Bu bölümde daha başarılı sonuçlar elde etmek amacıyla, ultrason görüntüleri BUSI ve BUS-UCLM veri setleri üzerinden 5 farklı Vision Transformer (ViT) varyasyonları ile gerçekleştirilmiş ve test edilmiştir. Bu çalışmada, standart Vision Transformer (ViT) modeli ve bu temel modelin 4 farklı versiyonu daha denenmiştir. Böylece hem orijinal modelin hem de daha gelişmiş Transformer mimarilerinin meme kanseri teşhisindeki başarısı ölçülmüştür.

Modellerin BUSI veri setindeki deneysel sonuçları aşağıdaki tabloda özetlenmiştir.

Tablo 5.15 BUSI veri seti üzerinde Transformer tabanlı modellerin sonuçları

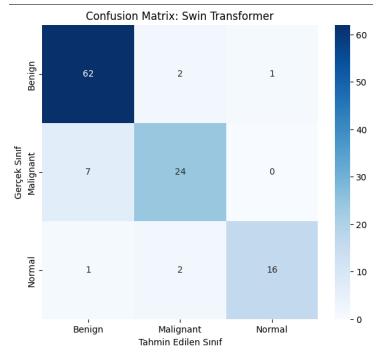
Model/Output	Accuracy	Recall	Precision	F1-Score
ViT (Standard)	0,8783	0,8685	0,8653	0,8655
DeiT-Tiny	0,8696	0,8465	0,8949	0,8677
Swin Transformer	0,8870	0,8567	0,8947	0,8737
CaiT	0,9130	0,8901	0,9310	0,9084
BEiT	0,8957	0,8754	0,9266	0,8953

BUSI veri seti üzerinde gerçekleştirilen deneysel sonuçlar, Vision Transformer tabanlı modellerin meme kanseri teşhisinde oldukça başarılı performans sergilediğini göstermektedir. Elde edilen bulgulara göre, en yüksek başarı CaiT modeli tarafından elde edilmiştir. Bu model, BUSI test verileri üzerinde %91,30 doğruluk oranına ve %93,10 kesinlik (precision) değerine ulaşmıştır. Bu sonuçlar, CaiT modelinin sağlıklı doku ile tümörlü yapıyı ayırt etme konusunda yüksek bir ayırt edicilik kapasitesine sahip olduğunu ortaya koymaktadır.

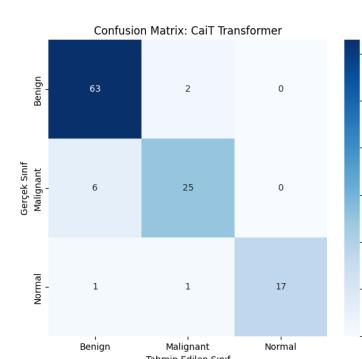
Bunun yanı sıra, BEiT ve Swin Transformer modelleri de BUSI veri seti üzerinde oldukça başarılı sonuçlar elde etmiştir. Bu modellerin yüksek performansı, ultrason görüntülerinde yer alan karmaşık yapısal detayları ve belirsiz doku sınırlarını etkin bir şekilde temsil edebilme yeteneklerinden kaynaklanmaktadır. Genel değerlendirme yapıldığında, BUSI veri seti üzerinde Transformer tabanlı yaklaşımının, yalnızca

lokal özelliklere odaklanmak yerine görüntünün tamamını küresel bağlamda analiz edebildiği görülmektedir. Elde edilen doğruluk oranlarının %90 seviyesinin üzerine çıkması, bu modellerin klinik karar destek sistemlerinde kullanılabilirliğini güçlü bir biçimde desteklemektedir.

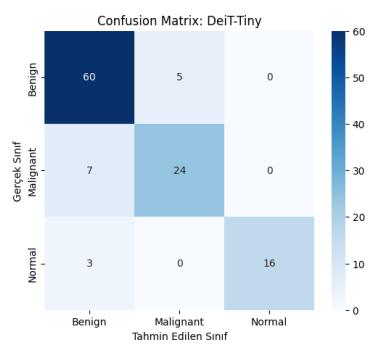
Aşağıda Transformer tabanlı modellerin BUSI veri setindeki sonuçlarına ait karmaşıklık matrisleri verilmiştir.



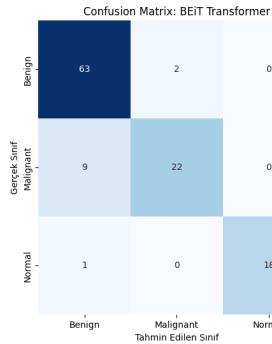
Şekil 5.7 Swin Transformer



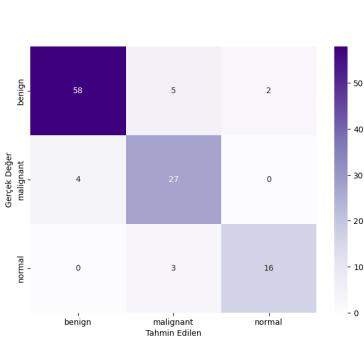
Şekil 5.8 CaiT Transformer



Şekil 5.9 DeiT Transformer



Şekil 5.10 BEiT Transformer



Şekil 5.11 ViT (Standard)

Şekil 5.12 Transformer Modellerine Ait Karmaşıklık Matrisleri

Modellerin BUS-UCLM veri setindeki deneysel sonuçları aşağıdaki tabloda özetlenmiştir.

Tablo 5.16 BUS-UCLM veri seti üzerinde Transformer tabanlı modellerin sonuçları

Model/Output	Accuracy	Recall	Precision	F1-Score
ViT (Standard)	0,9134	0,9135	0,9148	0,9133
DeiT-Tiny	0,8269	0,8269	0,8303	0,8282
Swin Transformer	0,9135	0,9135	0,9124	0,9124
CaiT	0,875	0,875	0,8759	0,8725
BEiT	0,8942	0,875	0,8759	0,8725

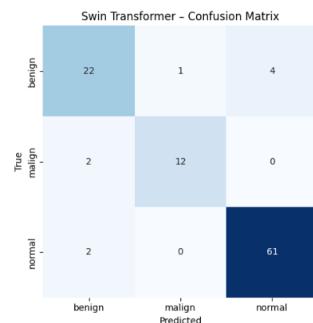
BUS-UCLM veri seti üzerinde gerçekleştirilen deneysel sonuçlar, Transformer tabanlı

modellerin meme kanseri teşhisinde etkili ve güvenilir performanslar sergilediğini ortaya koymaktadır. Tablo incelendiğinde, özellikle ViT (Standard) ve Swin Transformer modellerinin öne çıktıgı görülmektedir. Her iki model de yaklaşık %91,3 doğruluk (accuracy) ve %91 seviyelerinde precision, recall ve F1-score değerlerine ulaşarak, sağlıklı ve tümörlü dokuların ayırtılmasında yüksek bir başarı sağlamıştır.

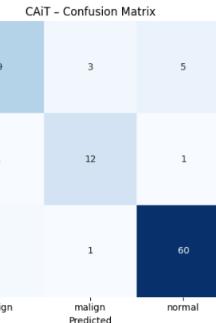
CaiT ve BEiT modelleri de BUS-UCLM veri seti üzerinde tatmin edici performanslar sunmuştur. Bu modellerin elde ettiği sonuçlar, Transformer mimarilerinin ultrason görüntülerinde karmaşık doku yapıları ve belirsiz sınırları etkili biçimde temsil edebildiğini göstermektedir.

DeiT-Tiny modeli ise daha hafif mimarisine bağlı olarak diğer modellere kıyasla görece daha düşük performans sergilese de, sınırlı hesaplama kaynakları gerektirmesi açısından pratik uygulamalar için avantajlı bir alternatif sunmaktadır.

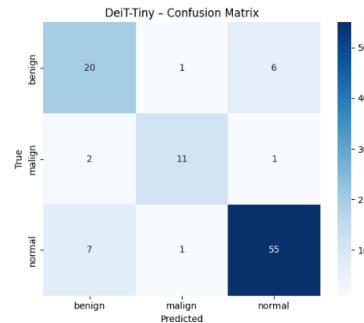
Aşağıda Transformer tabanlı modellerin BUS-UCLM veri setindeki sonuçlarına ait karmaşıklık matrisleri verilmiştir.



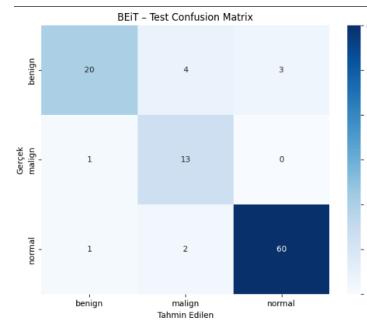
Şekil 5.13 Swin Transformer



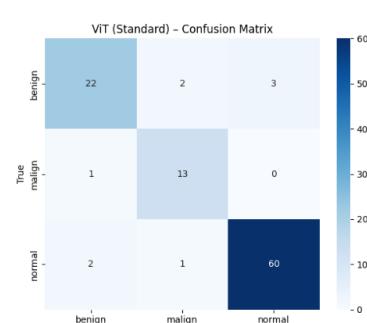
Şekil 5.14 CaiT Transformer



Şekil 5.15 DeiT Transformer



Şekil 5.16 BEiT Transformer



Şekil 5.17 ViT (Standard)

Şekil 5.18 Transformer Modellerine Ait Karmaşıklık Matrisleri

BUSI ve BUS-UCLM veri setleri üzerinde gerçekleştirilen deneysel çalışmalar, Vision Transformer tabanlı mimarilerin meme kanseri teşhisinde yüksek ve tutarlı

performanslar sunduğunu göstermektedir. BUSI veri setinde en yüksek başarıyı CaiT modeli elde ederken, BUS-UCLM veri setinde ViT (Standard) ve Swin Transformer modelleri yaklaşık %91 doğruluk oranlarıyla öne çıkmıştır. Elde edilen sonuçlar, Transformer tabanlı modellerin ultrason görüntülerindeki karmaşık doku yapıları ve belirsiz sınırları küresel bağlamda etkili biçimde analiz edebildiğini ortaya koymaktadır. Her iki veri setinde de %90 seviyesine yaklaşan veya bu seviyeyi aşan doğruluk, kesinlik ve F1-skor değerleri, bu mimarilerin meme kanseri teşhisinde güvenilir ve klinik karar destek sistemleri açısından uygulanabilir çözümler sunduğunu güçlü biçimde desteklemektedir.

5.2 Karşılaştırmalı Analiz

Alan uyarlaması sonuçları, klasik transfer öğrenme sonuçları (Tablo 5.1.2) ile kıyaslandığında, medikal görüntü özniteliklerinin bir veri setinden diğerine aktarılmasının önemi açıkça görülmektedir. ResNet-50: Alan uyarlaması stratejisinden en çok faydalanan model ResNet olmuştur. Klasik transfer öğrenme ile %78,02 doğruluk elde eden model, %30'luk kısıtlı bir eğitim verisiyle bile alan uyarlaması sayesinde bu oranı %84,33'e çıkarmıştır. Bu durum, ResNet mimarisinin BUSI veri setinden öğrendiği medikal doku ve kenar bilgilerini, BUS-UCLM veri setine çok daha hızlı ve verimli bir şekilde adapte edebildiğini kanıtlamaktadır. EfficientNet: EfficientNet modeli, alan uyarlaması senaryolarında en yüksek başarıyı sergileyen mimari olarak dikkat çekmektedir. Model %30 eğitim verisiyle %88,39, %50 eğitim verisiyle ise %92,6 doğruluk oranına ulaşarak klasik transfer öğrenme sonuçlarındaki başarıyı geçmiştir. Model özellikle "Normal" ve "Benign" sınıflarının tespitinde çok yüksek doğruluk oranına sahipken, veri setindeki kısıtlı örnek sayısı nedeniyle "Malignant" vakalarının sınıflandırılmasında zorlandı. Bu sonuçlar, EfficientNet'in kısıtlı sınıflarda veri miktarının hala kritik bir rol oynadığını göstermektedir. Xception: Klasik transfer öğrenme aşamasında %84,62 doğruluk ile en başarılı model olan Xception, alan uyarlaması senaryolarında (%30 için %71,85 - %50 için %71,66) bu başarısını koruyamamıştır. Bu durum, Xception modelinin BUS-UCLM veri setine doğrudan eğitildiğinde çok başarılı olmasına rağmen, BUSI veri setinden gelen ön-bilgilerin bu spesifik veri setindeki farklı klinik özelliklerle tam olarak örtüşmediğini işaret etmektedir. Özellikle BUS-UCLM verisinin BUSI verisine göre az olması bunun en büyük nedenidir. NasNetLarge: NasNetLarge modeli, her iki senaryoda da klasik transfer öğrenme başarısının (%75,96) bir miktar gerisinde kalarak %67-%69 bandında sonuçlar üretmiştir. Karmaşık ve derin mimarisi nedeniyle NasNet, alan uyarlaması sırasında daha fazla veriye veya daha hassas hiperparametre ayarına ihtiyaç duymaktadır; mevcut veri hacmi modelin alanlar arası geçişte potansiyelini tam yansıtmasını kısıtlamıştır. DenseNet ve InceptionV3: Her

iki model de %50 senaryosunda performanslarını artırarak klasik transfer öğrenme sonuçlarını yakalamış veya üzerine çıkmıştır. Özellikle DenseNet, %30 senaryosunda %78,25 doğruluk elde ederek düşük veriyle bile alan uyarlamasının klasik eğitime göre daha avantajlı olabileceğini (klasik eğitim %75) göstermiştir.

6 **SONUÇ VE TARTIŞMA**

Bu proje kapsamında derin öğrenme tabanlı 6 farklı CNN mimarisi ve 5 farklı Vision Transformer modeli kullanılarak transfer öğrenme ve alan uyarlaması yaklaşımlardan da faydalananacak şekilde meme ultrasın görüntülerinden tümör sınıflandırılması yapılmıştır. Tüm bu yaklaşımlar ve mimarilerden faydalananarak eğitilen modellerin başarısı ve elde edilen bulgular aşağıda değerlendirilmiştir.

BUSI veri setinde ImageNet üzerinde yapılan temel transfer öğrenme modellerinde en yüksek doğruluk oranına sahip modeller %86,96 doğruluk oranı ile EfficientNet ve %87,83 doğruluk oranı ile InceptionV3 modelleridir. EfficientNet, daha az parametreyle dengeli bir davranış sergileyerek lezyon özelliklerini başarıyla yakalarken, InceptionV3 farklı boyutlardaki evrişim filtreleriyle BUSI veri setindeki farklı tipteki lezyonların öz niteliklerini çıkarma konusunda diğer CNN modellerinden üstün olduklarını kanıtlamıştır. Fakat sonuçlar daha yeni nesil olan Vision Transformer mimarileri ile karşılaştırıldığında, çalışmada kullanılan 5 transformer modelinin de hem doğruluk değeri hem de diğer performans metrikleri bazında oldukça başarılı ve tutarlı bir performans sergilediği gözlemlenmiştir. Özellikle CaiT modeli %91,3 doğruluk oranıyla çalışmada elde edilen en yüksek başarıyı göstermiştir. Özellikle malignant sınıfına giren kötü huylu lezyonları yakalamada diğer modellerin önüne geçmiştir. Tüm bunlar göz önüne alındığında öz-dikkat mekanizmasıyla öne çıkan transformer tabanlı mimarilerin tümör dokularını anlamlandırmada ve sınıflandırmada CNN modellerinden daha başarılı olduğu kanıtlanmıştır.

Çalışmada elde edilen bulgular yalnızca eğitim stratejisinin ve kullanılan mimarilerin değil, kullanılan veri setinin boyutunun, özelliklerinin ve verilerinin dağılımının ne kadar önemli olduğunu ortaya koymuştur. Alan uyarlaması yaklaşımıyla BUSI veri setinde eğitilen modellerin BUS-UCLM veri setine uyarlanmasıyla elde edilen bulgular sonucunda, modellerinin çoğunun klasik transfer öğrenmeden daha başarılı bir sonuç elde ettiği görülmektedir. Eğitim kümesindeki veri oranı değiştirilerek iki farklı senaryo üzerinden yapılan deneylerde ResNet modeli, klasik transfer öğrenmedeki başarısının yaklaşık %10 üstüne çıkmıştır. Bu aşamada bazı modeller

eğitim verisinin az olduğu senaryolarda (%30) diğer modellere göre daha düşük performans sergilerken eğitim kümelerindeki veri oranı arttırıldığında çok daha iyi performans sergilemiştir. Bu durum, bazı modellerin alan uyarlaması yaklaşımına dirençli olabileceğini göstermektedir. Özellikle malignant kümelerdeki veri azlığı bu sonucu etkileyen önemli faktörlerdendir. Tüm bu bulgular göz önüne alındığında, medikal öznitelikleri başarılı bir şekilde öğrenmiş model üzerinden yapılan bilgi aktarımının yani alan uyarlamasının pozitif etkisini kanıtlamıştır.

Sonuç olarak bu çalışmada elde edilen bulgular, transformer modellerden özellikle CaiT modelinin, farklı veri setlerine uyum sağlama noktasında ise Efficient modelinin, meme kanseri tarama süreçlerinde uzmanlara bir karar destek mekanizması olarak kullanabileceğini göstermektedir.

6.1 Kısıtlamalar ve Gelecek Çalışmalar

Daha önce de bahsedildiği gibi çalışmanın temel kısıtlarından biri, malignant sınıfındaki doku görüntülerinin azlığıdır, özellikle CNN mimarileri bu kısıtlamadan etkilenmiş ve bu sınıfın dokuları ayırt etmekte zorlanmıştır. Daha dengeli bir veri setinde daha yüksek başarılar elde edilebileceği öngörlülmektedir. Xception ve Nasnet modelleri ise alan uyarlaması aşamasındaki zayıf performansı sebebiyle mevcut koşullarda ve bu problem bağlamında öncelikli bir seçenek olmayabilir.

Gelecek çalışmalarında CNN modelleri ile Transformer modellerinin birlikte kullanıldığı hibrit yaklaşımından faydalana bilir. Bununla birlikte çeşitli hastanelerden farklı ultrason cihazlarına ait görüntüler toplanarak ve ek olarak daha dengeli, büyük veri setleri kullanılarak modelin genelleme yeteneği artırılabilir. Model eğitiminde hastaya ilgili yaşı, genetik faktörler vb. farklı türde veri kaynaklarından yararlanmak da model eğitiminde faydalanailecek yaklaşımardan biridir.

Referanslar

- [1] C. Cruz-Ramos, O. García-Avila, J.-A. Almaraz-Damian, V. Ponomaryov, R. Reyes-Reyes, and S. Sadovnychiy, “Benign and malignant breast tumor classification in ultrasound and mammography images via fusion of deep learning and handcraft features,” *Entropy*, vol. 25, no. 7, 2023, ISSN: 1099-4300. [Online]. Available: <https://www.mdpi.com/1099-4300/25/7/991>.
- [2] H. Alrubaie, H. K. Aljobouri, Z. J. AL-Jobawi, and I. Çankaya, “Convolutional neural network deep learning model for improved ultrasound breast tumor classification,” *NJES*, vol. 26, no. 2, pp. 57–62, Jul. 2023. DOI: 10.29194/NJES.26020057.
- [3] S. Hossain *et al.*, “Automated breast tumor ultrasound image segmentation with hybrid unet and classification using fine-tuned cnn model,” *Heliyon*, vol. 9, no. 11, e21369, 2023, ISSN: 2405-8440. DOI: <https://doi.org/10.1016/j.heliyon.2023.e21369>. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2405844023085778>.
- [4] Q. He, Q. Yang, H. Su, and Y. Wang, “Multi-task learning for segmentation and classification of breast tumors from ultrasound images,” *Computers in Biology and Medicine*, vol. 173, p. 108319, 2024, ISSN: 0010-4825. DOI: <https://doi.org/10.1016/j.combiomed.2024.108319>. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0010482524004037>.
- [5] A. CALISKAN, F. F. ATES, and M. TOGACAR, “Ultrason tabanlı meme kanseri görüntülerinin derin öğrenme yaklaşımları ile sınıflandırılması,” *Firat Üniversitesi Fen Bilimleri Dergisi*, vol. 34, no. 2, pp. 179–187, 2022.
- [6] C. Kormpos, F. Zantalis, S. Katsoulis, and G. Koulouras, “Evaluating deep learning architectures for breast tumor classification and ultrasound image detection using transfer learning,” *Big Data and Cognitive Computing*, vol. 9, p. 111, Apr. 2025. DOI: 10.3390/bdcc9050111.
- [7] B. Liu, S. Liu, Z. Cao, J. Zhang, X. Pu, and J. Yu, “Accurate classification of benign and malignant breast tumors in ultrasound imaging with an enhanced deep learning model,” *Frontiers in Bioengineering and Biotechnology*, vol. 13, Jun. 2025. DOI: 10.3389/fbioe.2025.1526260.
- [8] K. Jabeen *et al.*, “Breast cancer classification from ultrasound images using probability-based optimal deep learning feature fusion,” *Sensors*, vol. 22, no. 3, 2022, ISSN: 1424-8220. [Online]. Available: <https://www.mdpi.com/1424-8220/22/3/807>.

- [9] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, “How transferable are features in deep neural networks?” *Advances in neural information processing systems*, vol. 27, 2014.
- [10] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, “Rethinking the inception architecture for computer vision,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 2818–2826.
- [11] C.-Y. Lee, S. Xie, P. Gallagher, Z. Zhang, and Z. Tu, “Deeply-Supervised Nets,” in *Proceedings of the Eighteenth International Conference on Artificial Intelligence and Statistics*, PMLR, 2015, pp. 562–570. [Online]. Available: <https://proceedings.mlr.press/v38/lee15a.html>.
- [12] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)*, vol. 97, pp. 6105–6114, 2019. arXiv: 1905.11946. [Online]. Available: <https://arxiv.org/abs/1905.11946>.
- [13] B. Zoph, V. Vasudevan, J. Shlens, and Q. V. Le, “Learning Transferable Architectures for Scalable Image Recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 8697–8710. [Online]. Available: <https://arxiv.org/abs/1707.07012>.
- [14] F. Chollet, “Xception: Deep Learning with Depthwise Separable Convolutions,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 1251–1258. [Online]. Available: <https://arxiv.org/abs/1610.02357>.
- [15] A. Dosovitskiy, “An image is worth 16x16 words: Transformers for image recognition at scale,” *arXiv preprint arXiv:2010.11929*, 2020.

Özgeçmiş

BİRİNCİ ÜYE

İsim-Soyisim: CEYDA BABUZ
Doğum Tarihi ve Yeri: 23.05.2002, İstanbul
E-mail: ceyda.babuz@std.yildiz.edu.tr
Telefon: 0542 896 57 99
Staj Tecrübeleri: Schneider Electric- Data Quality Intern

İKİNCİ ÜYE

İsim-Soyisim: MUHAMMED DİLBER
Doğum Tarihi ve Yeri: 06.11.2000, Ağrı
E-mail: muhammed.dilber@std.yildiz.tr
Telefon: 0543 592 80 22
Staj Tecrübeleri: TURKCELL Şirketi - Yapay Zeka Departmanı

Proje Sistem Bilgileri

Sistem ve Yazılım: Windows İşletim Sistemi, Python
Gerekli RAM: 2GB
Gerekli Disk: 256MB